

中国科学技术大学

专业硕士学位论文

工程硕士



基于卷积神经网络的 多指灵巧手抓取研究

作者姓名：宋方井

学科专业：控制工程

导师姓名：尚伟伟 副教授

完成时间：二〇一九年五月

University of Science and Technology of China
A dissertation for master's degree

Master of Engineering



Object Grasping of Multi-Fingered Hands
based on CNNs

Author: Fangjing Song

Speciality: Control Engineering

Supervisors: Associate Professor Weiwei Shang

Finished time: May , 2019

中国科学技术大学学位论文原创性声明

本人声明所呈交的学位论文,是本人在导师指导下进行研究工作所取得的成果。除已特别加以标注和致谢的地方外,论文中不包含任何他人已经发表或撰写过的研究成果。与我一同工作的同志对本研究所做的贡献均已在论文中作了明确的说明。

作者签名: _____

签字日期: _____

中国科学技术大学学位论文授权使用声明

作为申请学位的条件之一,学位论文著作权拥有者授权中国科学技术大学拥有学位论文的部分使用权,即:学校有权按有关规定向国家有关部门或机构送交论文的复印件和电子版,允许论文被查阅和借阅,可以将学位论文编入《中国学位论文全文数据库》等有关数据库进行检索,可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。本人提交的电子文档的内容和纸质论文的内容相一致。

保密的学位论文在解密后也遵守此规定。

☐公开 ☐保密 (____年)

作者签名: _____

导师签名: _____

签字日期: _____

签字日期: _____

摘要

抓取是机器人操作中的一项基本功能。选择合适的末端执行器能够提高机器人抓取物体的能力，一般来说末端执行器可以选择多指灵巧手或平行夹持器。相对于平行夹持器而言，多指灵巧手能够在一定范围内更好地抓取不同形状、尺寸和材质的日常物品。实用的灵巧手抓取规划算法能够使抓取更加稳定，因此本文对灵巧手抓取规划问题进行了研究。

受人类的灵巧抓取启发，本文提出了一种新颖的多级卷积神经网络，用于多指灵巧手精细抓取未知物体，并且设计了抓取品质的定量评估方法。将多级卷积神经网络的前三级称为抓取框检测网络，最后一级网络命名为抓取手势预测网络。抓取框检测网络通过物体 RGB-D 图像，快速且准确地检测到物体的最优抓取框。将得到的物体抓取框区域深度图作为抓取手势预测网络的输入，预测多指灵巧手的抓取手势，实现从未知物体 RGB-D 图像到多指灵巧手位姿与手势的映射。基于力封闭指标，设计了多指灵巧手的抓取品质定量评估方法，并在仿真环境 GraspIt! 中进行了测试。在实际的多指灵巧手 Shadow Hand Lite 上进行了抓取实验，结果表明所提出的多级卷积神经网络方法可以有效完成大量未知物体的精细抓取，并应用所设计的抓取品质定量评估方法，进一步验证所提出的多级卷积神经网络具有较好的抓取品质。

单纯地使用物体图像生成抓取手势，与人类以不同手掌姿态抓取物体的同一部位而抓取手势不同这一日常经验相违背。因此，本文对抓取手势预测网络进行了改进，设计了一个多输入的抓取手势预测网络。将物体的整体深度图、物体抓取框区域的深度图以及灵巧手手掌的抓取位姿作为输入，弥补原有网络的不足之处。从仿真实验结果可以看出，改进型抓取手势预测网络生成了高质量的抓取，证明了网络的有效性以及网络的泛化能力。在实际实验中，提升了对未知物体的抓取成功率，说明了改进型抓取手势预测网络的实用性。

从灵巧手的仿真对比实验结果中可以看出，灵巧手的抓取手势还有提升空间。为了优化灵巧手抓取手势，本文设计了一个预测灵巧手抓取质量的卷积神经网络。网络的输入是物体图像和灵巧手抓取位形，网络可以被视为物体图像信息和灵巧手抓取位形的函数。根据反向传播算法，计算抓取手势相对于抓取质量的梯度，最后利用梯度上升算法优化灵巧手的抓取手势。仿真实验结果验证了优化算法的有效性。

关键词：多指灵巧手 卷积神经网络 抓取规划 未知物体

ABSTRACT

Object grasping is an important ability of robots, and stable grasping of objects is one of the high performances of robots. Generally, multi-fingered hands are often selected as the end-effector to improve grasping ability of robots. Because multi-fingered hands can better grasp daily objects with respect to parallel grippers. And a practical grasp planning method for multi-fingered dexterous hands can make grasping more stable. Therefore, this dissertation studies the grasp planning method for multi-fingered hands.

Inspired by sophisticated grasp of human, we propose novel multi-level Convolutional Neural Networks (CNNs) for finely grasping of unknown objects with multi-fingered dexterous hands, and design a quantitative evaluation method for grasping quality. The first three levels can be considered as a grasping rectangle detection networks, and the last level can be considered as a grasping posture prediction network. Through the RGB-D image of an object, the grasping rectangle detection networks can quickly and accurately detect the optimal grasping rectangle of the object. The grasping posture prediction networks can predict the grasping posture of the multi-fingered dexterous hand by the depth image patch around the optimal grasping rectangle. The complete multi-level CNNs achieve mapping from the RGB-D image of the grasped object to the pose and posture of the multi-fingered dexterous hand. Based on the force closure metric, a quantitative evaluation method is developed to analyze the grasping quality in the simulator GraspIt!. The grasping experiments are carried out on an actual Shadow hand, and the experimental results indicate that the proposed multi-level CNNs can achieve finely grasping of unknown objects, by calculating the success rates and the quantitative evaluation values.

Generating grasping postures only depending on images is insufficient, since human tends to use different grasping postures when grasping the same object with different hand poses. To improve the output grasping postures, we propose a new grasping posture prediction networks with multi-inputs, which takes the overall depth image of the target object, the depth image patch of the grasping part and the pose of the dexterous hand as inputs. Experiments in simulation show that the proposed prediction network can produce high-quality grasping postures, which proves the validness and generality of our method. Besides, the proposed networks increase the

grasping success rate of previously unseen objects in actual experiments, implying the performance of our method in actual scenarios.

Simulation results show that the outputs of the grasping posture prediction networks can be improved further. To that end, we design a grasping quality prediction model based on convolutional neural network. The inputs to the model are images of the target object and the configuration of the dexterous hand. Hence, the model is a function of input components. The gradient of the grasping posture relative to the grasping quality is calculated using back propagation algorithm. And using gradient ascent algorithm to optimize the grasping posture. Finally, the validness of the new method is verified by simulation experiments.

Key Words: multi-fingered dexterous hand, convolution neural network, grasping planning, unknown object

目 录

第 1 章 绪论.....	1
1.1 课题研究背景和意义.....	1
1.2 研究现状.....	2
1.2.1 多指灵巧手的研究现状.....	3
1.2.2 灵巧手抓取规划研究现状.....	6
1.3 主要研究内容.....	8
1.4 论文的章节安排.....	9
第 2 章 相关基础知识.....	11
2.1 抓取质量.....	11
2.2 卷积神经网络.....	12
2.2.1 卷积层	12
2.2.2 池化层	13
2.2.3 全连接层	14
2.2.4 反向传播算法.....	15
2.3 回溯线搜索.....	16
2.4 本章小结.....	17
第 3 章 基于多级卷积神经网络的灵巧手抓取规划.....	19
3.1 问题分析.....	19
3.2 抓取框的定义.....	19
3.3 多级卷积神经网络结构设计.....	20
3.3.1 第一级网络结构.....	21
3.3.2 第二级网络结构.....	21
3.3.3 第三级网络结构.....	21
3.3.4 第四级网络结构.....	22
3.4 灵巧手手掌位姿的确定.....	22
3.5 基于多级网络的抓取模型.....	23
3.6 数据集生成与网络训练.....	24
3.6.1 抓取框检测网络数据集.....	24
3.6.2 抓取手势预测网络数据集.....	24
3.6.3 网络训练	25

3.7 实际实验.....	25
3.7.1 抓取实验与结果.....	26
3.7.2 抓取质量评估.....	28
3.8 本章小结.....	29
第 4 章 灵巧手的改进型抓取手势预测网络.....	31
4.1 问题分析.....	31
4.2 改进型抓取手势预测网络.....	32
4.3 灵巧手手掌位姿的确定.....	34
4.4 基于多级网络的抓取模型.....	34
4.5 数据集的生成.....	35
4.6 仿真实验结果.....	37
4.6.1 网络结构合理性验证.....	37
4.6.2 仿真对比实验.....	39
4.7 实际实验.....	41
4.8 本章小结.....	42
第 5 章 基于手势优化的灵巧手抓取规划.....	43
5.1 问题分析.....	43
5.2 网络结构设计.....	44
5.3 数据集的生成和网络的训练.....	45
5.4 优化抓取手势.....	45
5.5 实验结果.....	46
5.6 本章小结.....	48
第 6 章 总结与展望.....	49
6.1 总结.....	49
6.2 展望.....	50
参考文献.....	51
致 谢.....	57
在读期间发表的学术论文与取得的研究成果.....	59

第 1 章 绪论

1.1 课题研究背景和意义

机器人总共经历了三次关键的技术革新。第一代机器人出现在上世纪 50 年代, 1959 年德沃尔和约瑟夫共同开发了第一台真正意义上的工业机器人, 第一代机器人缺少外部信息获取能力, 只能按照事先编写的程序进行工作, 完成一些简单的任务。时至今日, 第一代机器人技术已经完全成熟, 第一代机器人广泛地工作在工厂一线。第二代机器人技术是从 20 世纪 60 年代开始发展的, 1962 年博尼和托莫维奇在世界上最早的灵巧手机器人上安装了触觉传感器。第二代机器人在第一代机器人的基础上加入感知系统, 如视觉、力觉和触觉等, 感知系统的安装提高了机器人的性能。第三代机器人技术则将感知与智能化结合在一起, 使机器人具有感知、推理、规划、学习和决策等能力。智能化的机器人能适应各种复杂场景, 能够执行拟人的操作, 自主完成复杂任务, 具有广泛的应用前景。目前, 第三代机器人技术正在不断发展着, 第三代机器人正处于试验阶段。

最近十几年来, 随着第三代机器人技术的发展, 机器人的应用领域在快速扩展, 从工业到军事、服务、家用以及娱乐等领域。各行业对机器人的需求在日益增加, 同时对机器人的性能要求也越来越高, 对任务的要求也越来越复杂。除去从事特殊工作的机器人, 如焊接机器人、喷漆机器人等, 抓取一直都是机器人的一项基本功能, 稳定地抓取物体更是机器人高性能的表现之一。大部分的机器人都是由一个多自由度的机械臂加上一个末端执行器组成的, 机械臂用于实现末端执行器接近物体的过程, 末端执行器完成抓取操作。由于末端执行器是机器人与环境产生交互的部件, 因此选择合适的机器人末端执行器能够提高机器人抓取物体的能力。一般来说末端执行器可以选择多指灵巧手或两指夹持器, 如图 1.1 所示。从图 1.1 中可以看出两指夹持器的机械结构简单, 规划它的抓取手势只需要一个变量, 因此两指夹持器的抓取规划十分简单。然而它是对物体施加方向相反的压力来实现抓取操作的, 导致抓取的稳定性较差。而多指灵巧手相对于两指夹持器而言, 能够更好地抓取任意形状、尺寸和材质的日常物品, 能够在执行操作任务期间保持物体的稳定性, 并且能够不只是依赖于执行器与物体之间的摩擦力来完成抓取任务。理论上, 仿照人手的多指灵巧手能完成人手所能完成的所有工作, 它是一款通用型末端执行器。因此, 研究者们通常将机器人的末端执行器从简单的两指夹持器升级为多指灵巧手。为了不断提升多指灵巧手的性能, 满足更高要求的抓取操作, 研究者们不仅在灵巧手的机械结构上不断改进, 而且也提出

了各种适用的抓取规划方法。



图 1.1 末端执行器

灵巧手抓取规划算法指对于给定的物体,能够根据物体的位形确定被抓物体表面上合适的接触点个数和位置^[1],或者稳定的灵巧手抓取位形,其中灵巧手的抓取位形包括灵巧手自身的位姿以及抓取手势。一般来说,多指灵巧手的抓取规划方法分为分析法和经验法。分析法主要分析目标物体的形状,就是将物体的几何信息作为输入去计算接触点,它们通常基于某一抓取质量指标进行优化,选择最优的抓取位形,实现抓取操作。由于分析法是基于精确的物体三维信息和机器人模型,而在现实环境中获取物体三维信息的难度较大,所以分析法难以用于实际应用中。因此,在智能机器人领域大多采用经验法实现机器人抓取目标物体。近十年来,由于人工智能的高速发展,大量的机器学习算法被引入到经验法中。其中,由于卷积神经网络能够自动提取图像的特征,在图像理解上有着巨大优势,所以卷积神经网络被用于各种图像处理任务中。将卷积神经网络应用在多指灵巧手抓取操作上有着重大作用,利用卷积神经网络快速且准确地提取图像中目标物体的特征,从而得到物体的最佳抓取手势,实现对未知物体的抓取。

1.2 研究现状

近年来,拟人化的多指灵巧手成为了机器人末端执行器的主要研究方向。研究者们除了不断优化多指灵巧手的机械结构,还在灵巧手上安装多种传感器,极大地提高了灵巧手的拟人程度。除了结构上的优化,各种灵巧手抓取规划算法被

提出,使得灵巧手能够面对复杂的抓取环境,并且对各种各样的物体都能实施高稳定性和高质量的抓取操作。

1.2.1 多指灵巧手的研究现状

最早的灵巧手是 1962 年博尼和托莫维奇研制的 Belgrade 手,他们在 Belgrade 手上安装了压力传感器,使其能够感知外部接触力^[2]。随后机器人技术的发展以及机器人应用场景的增加,都大大地促进了灵巧手的发展。1974 年,日本的研究者们开发了 Okada 手^[3],如图 1.2 所示。Okada 灵巧手只有 3 个手指,除了大拇指是 3 自由度的,其余两指均是 4 自由度,每个手指关节都是由电机通过钢丝-滑轮实现驱动的,能够完成拧螺栓之类的简单工作。




图 1.2 Okada 手



图 1.3 Utah/MIT 灵巧手



图 1.4 Salisbury 手

上世纪 80 年代,随着机器人技术的累积,研究者在灵巧手的研制上取得了许多突破性的成果,涌现出一批具有代表性的多指灵巧手。1980 年,美国犹他大学和麻省理工学院共同研制了 Utah/MIT 灵巧手^[4],如图 1.3 所示。Utah/MIT 灵巧手的手指位置分布类似人手,但只有四个手指,每个手指都是 4 自由度的,使用了气动伺服缸作为关节的驱动件,通过绳索-滑轮机构实现动力传动。此外,该灵巧手手指表面安装了触觉传感器,能够粗略感知接触物体的表面特征。美国斯坦福大学研制了 Salisbury 灵巧手^[5],如图 1.4 所示。该手共有三个手指,采用

了模块化设计，每个手指的结构完全一致，手指自由度为 3，其中一个手指与其余两个手指相对放置。上述的两款多指灵巧手为后续的多指灵巧手设计提供了很多设计思想，如模块化的手指结构、搭载触觉等多种传感器。同时它们也为多指手抓取规划算法以及控制策略等理论研究提供了良好的实验平台。

20 世纪 90 年代，随着微电机学、集成电路等技术的发展，多指灵巧手再次迎来了发展的浪潮，多指灵巧手的拟人化程度越来越高。这一时期灵巧手的主要研究机构以意大利、德国和美国为主。其中，意大利研制了 DIST^[6]、UB 手^[7]，它们易于安装在各种机械臂上，从而进行完整的拟人手臂操作实验。德国宇航中心开发了 DLR-I 手^[8-9]，如图 1.5 所示。该手只有四个手指，且每个手指的结构完全一致，手指的末端两关节机械耦合与人手类似。DLR-I 手每个手指上都安装了 28 个传感器，比如：触觉传感器、力矩传感器、温度传感器以及关节角度传感器等，众多的传感器为它提供了良好的感知能力。1999 年美国宇航中心研制了 NASA Robonaut 手^[10]，用于空间站的舱外作业，如图 1.6 所示。NASA Robonaut 手共有 14 个自由度，大拇指、食指和中指均有 3 个自由度，无名指和小拇指只有 1 个自由度，手掌有 1 个自由度，手腕有 2 个自由度，该手在外形上与人手十分相似。与 DLR-I 手一样，NASA Robonaut 手也安装了多种传感器，总共有 43 个传感器。



图 1.5 DLR-I 手



图 1.6 NASA Robonaut 手



图 1.7 DLR-II 手

进入 21 世纪，灵巧手的研制正在稳步进行中，多指灵巧手越来越集成化和智能化。由全数字机电集成思想指导，以 DLR-I 为基础，德国宇航中心成功研制了第二代多指灵巧手 DLR-II^[11]，如图 1.7 所示。在机械结构上 DLR-II 与 DLR-I 类似，也是四个手指，每个手指 4 个关节和 3 个自由度。不同的是，DLR-II 的大拇指有一个相对于手掌的自由度，提高了灵巧手的灵活性，以满足不同的任务要求。DLR-II 的驱动器采用无刷直流电机，同时对 DLR-II 的传动机构进行了优化，使得 DLR-II 能输出比 DLR-I 更大的力，并且具有更高的可靠性。除了优化机械系统，DLR-II 实现了电气系统的完全集成化和数字化，大幅度减少与主处理器的连接线，从 DLR-I 的 400 多条锐减到 8 条。

日本岐阜大学研制了 Gifu 系列的灵巧手^[12], 如图 1.8 所示。其中 Gifu-III 由 5 个手指构成, 该手在外观上与人手也十分相似, 一共有 20 个关节和 16 个自由度。大拇指有 4 个关节和 4 个自由度, 其余手指都是 4 个关节和 3 个自由度, 手指末端的两个关节机械耦合。与其他灵巧手相比, Gifu-III 最大的特点是, 覆盖在灵巧手表面上具有 859 个检测点的分布式触觉传感器, 如图 1.8 所示。



图 1.8 Gifu-III 手和分布式触觉传感器

英国的 Shadow 机器人公司开发了 Shadow Hand 系列的灵巧手^[13], 这一系列的灵巧手是拟人多指灵巧手商业化的典型代表, 如图 1.9 所示。Shadow Hand 的每个手指上均安装了绝对位置和力传感器, 以及指尖上安装了压力传感器。Shadow Hand 系列的灵巧手有着与人类接近的自由度, 大小也十分接近人手, 每个关节的移动范围与人手的移动范围相同或非常接近, 高度的拟人化大大增加了灵巧手的操作能力。



图 1.9 Shadow Hand 系列

从 20 世纪 80 年代起, 国内才开始了多指灵巧手的研究工作。1993 年北京航空航天大学成功研制了第一个三指灵巧手 BUAA-I, 随后又在其基础上研制了改进型的 BUAA-II~ BUAA-IV, BUAA-III 灵巧手如图 1.10 所示^[14]。该系列的灵巧手采用了模块化设计, 其中最新型的 BUAA-4^[15]在外形上最接近人手, 拟人化程度最高, 能够完成复杂的任务。哈尔滨工业大学和德国宇航中心合作开发了 HIT/DLR 系列的多指灵巧手, 如图 1.11 所示^[16-17]。HIT/DLR 采用机电一体化设

计思想,将所有驱动元件、传动机构和电气系统等全部都安装在灵巧手本体机械内部,极大减低了对外部条件的依赖程度^[17]。近年来,我国在微型传感器、微型电机、控制理论等机器人相关领域取得了突破性的研究进展,这极大地推动了我国多指灵巧手的发展。




图 1.10 BUAA-III 灵巧手



图 1.11 HIT/DLR 系列灵巧手

1.2.2 灵巧手抓取规划研究现状

灵巧手抓取规划算法指对于给定的物体,能够根据物体的位形确定被抓物体表面上合适的接触点个数和位置,或者稳定的灵巧手抓取位形,其中灵巧手的抓取位形包括灵巧手自身的位姿以及抓取手势。在无限的抓取位形空间中为目标物体找到合适的抓取是一个极具挑战性的问题,并且是机器人研究中不可避免的问题,为此国内外的研究者们研究出了大量的抓取规划算法。

一般而言,抓取规划方法可以分为分析法和经验法^[18]。分析法主要分析目标物体的形状,就是将物体的几何信息作为输入去计算接触点。它们通常基于某一抓取质量指标进行优化,选择最优的抓取位形,实现抓取操作,将抓取规划问题转换为带约束的优化问题^[19]。其中被广泛应用的抓取质量指标有 ε 指标,该指标是抓取的力封闭指标,由 Kirkpatrick 等人^[20]提出, Ferrarri 和 Canny^[21]发展并改进了该方法。Clocarlie 和 Allen^[22]通过主成分分析降低高维度的手势空间,构建了一个低维度手势子空间,并在灵巧手上设置期望接触点用来计算预抓取时的力封闭指标。通过最大化力封闭指标,可以快速搜索出高质量的抓取手势,但这种方法需要准确的灵巧手模型和物体模型,不适用于实际场景中的未知物体抓取。另外, Nguyen^[23]提出了独立接触区域 (ICRs) 的概念:物体上的一组区域,每个手指可以放在区域内的任意一点,而由这些接触点所构成的抓取不会丢失力封闭的特性。根据所得到的接触点,通过灵巧手的逆运动学计算得到灵巧手的抓取手势。Roa 和 Suárez^[24]设计了一种有效计算 ICRs 的算法,用于计算任何三维物体表面上任意数量的无摩擦或摩擦接触的 ICRs,

但该算法所需时间较长,无法满足实际抓取过程的实时性要求,并且同样依赖于物体的完整三维模型。除此之外, Stanimir^[25]等人使用触觉传感器接触物体,通过传感器数据计算高斯过程隐式表面,从而估计物体形状,最后将得到的结果作为抓取规划的基础,从而计算物体的接触点。除了上述提到的方法,还有很多工作都依赖于物体的三维模型来计算接触点^[26-29]。可以看出,大多数分析方法都需要准确的灵巧手运动学模型和物体模型,因此它们只适用于已知物体抓取,并且需要耗费大量的物体建模时间。到目前为止,分析法的应用有很大的局限性,它们只能用在仿真环境中或者考虑二维物体以及简单的三维物体。

考虑到分析法的局限性,基于机器学习的经验法被广泛应用于抓取规划,并且效果显著^[30-31]。Saxena^[32]等人对一个逻辑斯蒂回归模型进行训练,通过大量标记数据的训练,模型能够从单目图像中预测物体的单一抓取点。Le^[33]等人拓展了上述的方法,从而实现多个接触点的抓取。然而抓取点只是低维的抓取信息,它们只代表了部分的抓取,因此这种方法只是次优解。Jiang 等人^[34]提出了抓取框表示抓取的形式,通过一个在图像中定向的矩形表示夹持器的位姿,但是需要人工设计特征。随后 Lenz 等人^[35]、Redmon 和 Angelova^[36]在抓取框的基础上,采用卷积神经网络对物体抓取进行检测,利用卷积神经网络自主提取特征的能力,避免了人工设计特征。更进一步的,受残差网络^[37]和 Faster R-CNN^[38]的启发,Kumra 等人^[39]、Guo 等人^[40]提出了新颖的网络结构,如:多模态的深度卷积网络,用来预测最优的抓取矩形框。除此之外,还有很多研究工作将深度学习用于抓取框检测上^[41-44]。上述引入抓取框的抓取规划算法使得未知物体的抓取成功率很高,但只适用于夹持器,并且对于圆锥体等具有倾斜度的物体平行夹持器难以抓取,而多指灵巧手却能执行这种任务。显然,多指灵巧手不能像夹持器一样简单地闭合,需要研究多指灵巧手的抓取手势,只有合适的抓取手势才能稳定地抓取物体。

现阶段,相对于平行夹持器,只有少量的工作将深度学习用于难度更大的多指灵巧手抓取规划。Varley 等人^[45]设计了一种卷积网络结构,对抓取时的图像进行分析,通过以灵巧手手掌和指尖位置为中心的局部图像能有效地预测当前状态下多指灵巧手的抓取质量,同时将预测得到的抓取质量作为外部规划器抓取质量函数的一部分,再通过外部规划器提供候选抓取位形。然而,依赖于外部规划器的抓取规划算法是无法直接提供抓取位形的,这使得抓取规划过程过于繁杂。Kapper 等人^[46]训练了一个卷积神经网络,在灵巧手预抓取手势固定的情况下,预测给定某一灵巧手位姿的抓取成功概率,通过对一系列的抓取位姿进行评估,选择抓取成功率最大的位姿进行抓取操作。Saxena 等人^[47]通过学到的抓取成功

概率模型对抓取位形进行推断,使用场景的点云数据和图像数据来推断抓取位形,但是他们使用了两个概率模型分别对点云数据和图像数据进行处理,而不是在一个统一的概率模型中。**Zhou** 和 **Hauser**^[48]设计了一种多输入的卷积神经网络结构,使用灵巧手的抓取位姿信息和物体顶部深度图预测抓取质量,为了在六维灵巧手位姿空间中生成有效的抓取,他们引入了一种新颖的优化方法,使用学习到的抓取质量函数对当前的抓取位姿进行优化。但是他们只对抓取位姿进行了优化,没有涉及灵巧手的抓取手势优化。**Lu** 等人^[49]使用了与 **Zhou**^[48]类似的卷积神经网络结构。不同的是, **Lu** 等人的网络输出结果是抓取成功概率,将抓取规划视为概率推断问题。另外, **Lu** 等人考虑了灵巧手的抓取手势,他们将灵巧手的抓取位姿和抓取手势结合在一起作为网络的输入。

除了将卷积神经网络用于预测抓取成功概率或抓取质量外,研究者们也设计了回归网络,将网络用于直接预测抓取位形。**Ficuciello** 等人^[50]用长、高、直径表示物体,再加上抓取类型构成一个抓取特征向量,将这个向量输入网络预测灵巧手的抓取手势,但是它只能用于简单的物体或者用长宽高简化物体模型。**Veres** 等人^[51]训练了一个条件变分自编码深度网络,在给定物体的 RGB-D 图像的情况下,预测多指灵巧手抓取的接触点位置和法线。为了执行抓取操作,必须额外使用灵巧手的运动学反解器,并且要确保预测的接触位姿可以到达。在 **Veres** 等人的工作中,隐含的假设是对给定的物体图像只存在唯一的最优抓取位形。

1.3 主要研究内容

本文的研究内容是基于卷积神经网络的多指灵巧手抓取规划,主要包含以下三方面:

1) 由于抓取规划算法中分析法需要精确的物体三维信息和机器人模型,而在实际应用时通常难以获取物体三维信息,因此本文设计了一种新颖的卷积神经网络结构,直接从物体图像信息中预测灵巧手抓取位形,实现了未知物体的抓取。最后,在 **Shadow Hand Lite** 灵巧手与 **UR5** 机械臂组成的拟人手臂上进行抓取操作,测试所设计的卷积神经网络的性能,并在 **GraspIt!** 仿真软件中评估网络预测的抓取位形。

2) 考虑到灵巧手抓取手势不仅与目标物体的被抓取部位有关,还与灵巧手抓取时的位姿相关。本文设计了一种多输入的卷积神经网络,实现在不同灵巧手抓取位姿的情况下抓取手势的生成。网络所需的灵巧手抓取数据是在 **GraspIt!** 仿真环境中生成的,避免了人工采集数据费时费力,且没有抓取手势评价标准等缺点。最后,在 **GraspIt!** 中验证所设计的网络结构的合理性,并与其他三种抓取方

法进行对比，验证所设计的网络的优越性。同样的，在 Shadow Hand Lite 灵巧手与 UR5 机械臂组成的拟人手臂上进行抓取操作，测试所设计的卷积神经网络的性能。

3) 为了提高灵巧手的抓取质量，设计一种能够预测灵巧手抓取质量的卷积神经网络结构。利用卷积神经网络自身的反向传播算法，计算相关梯度。采用梯度上升算法优化抓取手势，从而最大化抓取质量。最后，在 GraspIt! 中测试网络的性能。

1.4 论文的章节安排

本文的具体章节安排如下：

第一章详细地阐述了本文的研究背景和意义，介绍了国内外多指灵巧手的发展状况，列举说明了多指灵巧手抓取规划现状，最后简要说明本文的研究内容。

第二章介绍了抓取规划中的力封闭指标，以及一些基本的卷积神经网络基础知识。

第三章主要介绍了抓取框的定义以及多级抓取网络的结构，根据抓取框的位姿推导灵巧手的位姿，说明多级抓取网络数据集的选择和生成。最后，在实际机器人上测试多级抓取网络的性能，在 GraspIt! 仿真软件中评估多级抓取网络所生成的抓取位形。

第四章首先分析了第三章抓取手势预测网络所没有考虑到的问题，接着改进了抓取手势预测网络，之后介绍了抓取手势预测网络数据集的生成过程。最后，在 GraspIt! 中验证网络的合理性，并给出与其它抓取规划算法的仿真对比结果；在实际拟人手臂上进行抓取操作，检验本章所提出的抓取规划算法的性能。

第五章主要内容是设计了一个灵巧手抓取质量预测网络，介绍灵巧手抓取手势优化过程，在 GraspIt! 中测试网络的性能。

第六章总结了本文基于卷积神经网络的多指灵巧手抓取规划研究的成果，并展望了多指灵巧手抓取物体的进一步研究方向。

第 2 章 相关基础知识

2.1 抓取质量

灵巧手抓取规划算法能够针对给定的物体，给出被抓物体表面上合适的接触点或者稳定的灵巧手抓取位形，其中灵巧手的抓取位形包括灵巧手自身的位姿以及抓取手势。大多数的抓取规划算法都是分析法，就是将物体的几何信息作为输入去计算接触点，它们通常基于某一抓取质量指标进行优化，选择最优的抓取位形，实现抓取操作。分析法最常用的指标是力封闭指标，之后本文也会根据这个指标对我们提出的方法所产生的抓取进行评估，并通过最大化力封闭指标，优化抓取手势。

为了计算力封闭指标，我们需要对抓取建立一个抓取扭矩空间（Grasp Wrench Space, GWS），抓取扭矩空间是在物体上各个接触点所施加的扭矩形成的空间。首先，需要将灵巧手与物体接触点处的摩擦锥近似为围绕锥体边界的有限数量的力矢量的凸组合：

$$f_i = \sum_{j=1}^k \alpha_{i,j} f_{i,j} \quad \alpha_{i,j} \geq 0 \quad (2.1)$$

式中， f_i 是第 i 个接触点的接触力， $f_{i,j}$ 是第 i 个接触点的第 j 个力向量， $\alpha_{i,j}$ 是第 i 个接触点第 j 个力向量的权重系数。根据式 (2.1) 计算每个力矢量关于物体质心的扭矩：

$$w_i = \begin{bmatrix} f_i \\ p_i \times f_i \end{bmatrix} = \begin{bmatrix} \sum_{j=1}^k \alpha_{i,j} f_{i,j} \\ p_i \times \sum_{j=1}^k \alpha_{i,j} f_{i,j} \end{bmatrix} = \sum_{j=1}^k \alpha_{i,j} \begin{bmatrix} f_{i,j} \\ p_i \times f_{i,j} \end{bmatrix} = \sum_{j=1}^k \alpha_{i,j} w_{i,j} \quad (2.2)$$

式中， w_i 是第 i 个接触点的扭矩， p_i 表示物体质心到第 i 个接触点的距离矢量。计算这组扭矩构成的凸包，这个凸包就是抓取扭矩空间 (GWS)：

$$W_{L_i} = \text{ConvexHull}(\bigcup_{i=1}^n \{w_{i,1}, \dots, w_{i,k}\}) \quad (2.3)$$

由于三维空间抓取中力矢量是一个三维向量，因此所生成的扭矩是一个六维向量，所形成的凸包在六维空间中。如果原点没有被包含在该空间中，则表明这个抓取不是力封闭的，意味着存在一些当前抓取无法抵制的扰动扭矩。当原点被包含在凸包内时，此次抓取的质量就等于原点到最近凸包平面的距离，即凸包内以原点为中心的球体的半径 ε 。力封闭指标 ε 的取值范围为 0~1 且越接近 1 表明抓取越稳定，但在实际抓取中力封闭指标的值一般比较小，大多数都小于 0.1。

如图 2.1 所示就是一个简单平面圆形抓取例子，图 2.1 (a) 表示平面圆形物体上的三个抓取接触点以及它们的摩擦锥。由于平面抓取的力矢量是二维向量，因此所生成的扭矩是一个三维向量，图 2.1 (b) 中带箭头的实线表示扭矩矢量，其余实线代表扭矩构成的凸包，虚线表示凸包的内接球。

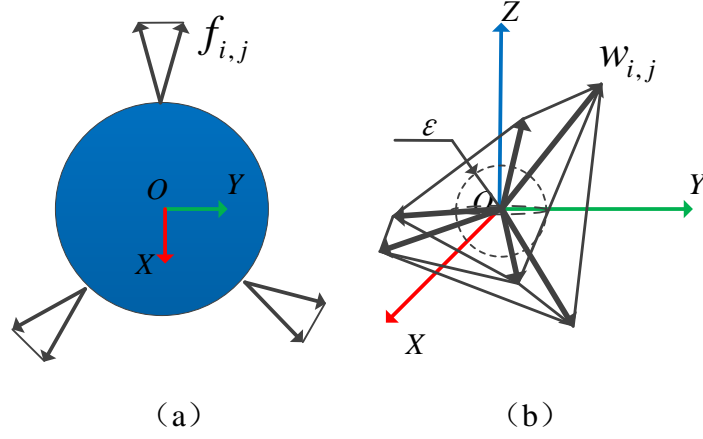


图 2.1 抓取扭矩空间示意图

2.2 卷积神经网络

卷积神经网络 (Convolutional Neural Network, CNN) 是一种具有权值共享、局部连接等特性的深层前馈神经网络，这些特性使得卷积神经网络具有一定程度上的平移和缩放不变性。卷积神经网络一般由卷积层、池化层和全连接层组成，采用反向传播算法进行训练。卷积神经网络主要用于图像处理等各种任务上^[52-54]，比如：物体识别、图像分类等，其处理结果远好于其他图像处理方法。

2.2.1 卷积层

卷积层是对图像进行卷积处理的网络层，卷积是图像处理中有效的图像特征提取方法，经过卷积操作后得到的图像称为特征映射或特征图，假设给定一幅图像 X 和一个卷积核 W ，其卷积结果为

$$y_{i,j} = \sum_{u=1}^m \sum_{v=1}^n w_{u,v} \cdot x_{i-u+1,j-v+1} \quad (2.4)$$

其中， $y_{i,j}$ 是特征图中第 i 行 j 列的像素点， $w_{u,v}$ 是卷积核上第 u 行 v 列的值， mn 是卷积核的大小， $x_{i-u+1,j-v+1}$ 是输入图像中第 $i-u+1$ 行 $j-v+1$ 列的像素点。卷积核在图像上按一定步长进行移动，从而得到输出图像，图像卷积的具体过程如图 2.2 所示。卷积层的作用是提取图像局部区域的特征，不同的卷积核提取不同的

图像特征。为了提高卷积神经网络的性能，基本上每一个卷积层都使用多个不同的卷积核，以更好地提取图像中的多个特征。

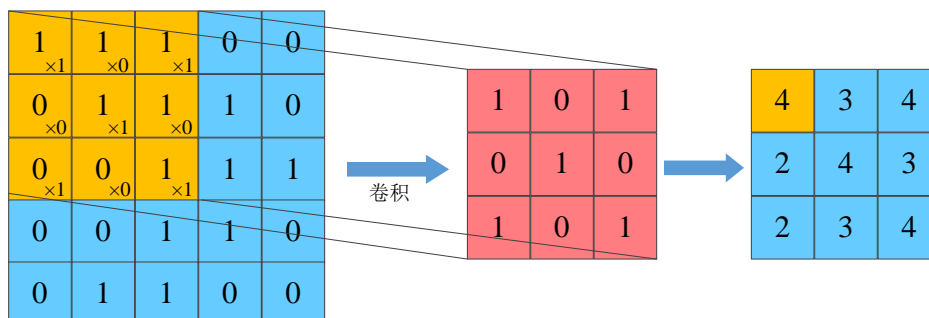


图 2.2 卷积过程

2.2.2 池化层

池化层也被称为下采样层，其最主要的作用是筛选特征。减少特征数量从而降低数据量，同时也减少了网络的参数数量，防止网络出现过拟合。一般图像经过卷积层后再经过池化层。最常用的池化层有两种，一种是最大池化层，另一种是平均池化层。最大池化层是选择区域内的最大值，平均池化层是取区域内的平均值，两种池化过程如图 2.3 所示。池化层也可以看作是一个特殊的卷积层，一般池化层的核大小选择 2×2 ，步长大小也为 2×2 ，因为池化层的核过大会急剧减少图像特征，造成过多的信息损失。




图 2.3 最大池化过程和平均池化过程

除了常用的最大池化和平均池化，有时候也会因为特殊需求采用特殊的池化层，比如：为了使输入图像大小可变，采用空间金字塔池化层^[55]。在一般的卷积神经网络中，通常需要输入图像的大小是固定的，这是因为卷积网络中的全连接层对输入特征向量的大小要求是固定的。可以预见，如果输入图像大小变化，则经过卷积层再展开的特征向量的大小也会变化的，而全连接层是无法处理大小变化的输入特征向量。一般对于大小不一的输入图像，需要经过裁剪或缩放，使得经过预处理的输入图像与网络要求的图像大小保持一致。但经过预处理的图像可能会丢失某些关键的图像信息，从而导致网络输出结果变差。

在卷积层和全连接层之间加入空间金字塔池化层，能够使网络接受任意大小的输入图像，且输入图像不需要经过预处理。如图 2.4 所示就是一个空间金字塔池化过程，输入一张任意大小的特征图，要求提取一个 21 维的特征向量。首先，对特征图进行 3 次划分，每次划分的刻度大小不同，一共得到 21 个小块；接着，从每一小块中通过最大池化或者平均池化提取一个特征；最后，将 21 个特征连接在一起就得到了我们需要的 21 维特征向量。

空间金字塔池化层相当于在一张特征图上使用大小不同的卷积核对特征图进行池化操作，连接经过池化后的特征得到固定大小的特征向量。




图 2.4 空间金字塔池化过程

2.2.3 全连接层

全连接层是卷积神经网络中的最后一部分，也是非常重要的组成部分，其作用是将图像的特征空间映射到样本的标记空间。全连接层就是前馈神经网络，将卷积层的特征图展开以特征向量的形式输入全连接层，卷积层到全连接层的信息传递过程如图 2.5 所示。




图 2.5 卷积层到全连接层的信息传递过程

全连接层通过下面公式进行信息传递：

$$a^{(l)} = f_l(W^{(l)} \cdot a^{(l-1)} + b^{(l)}) \quad (2.5)$$

其中, l 代表全连接层的层数, $a^{(l)}$ 是全连接层第 l 层的输出, $f_l(\cdot)$ 表示全连接层第 l 层的激活函数, $W^{(l)}$ 是 $l-1$ 层到 l 层的权值矩阵, $b^{(l)}$ 是 $l-1$ 层到 l 层的偏置。

2.2.4 反向传播算法

给定一个样本 x , 输入到网络, 数据在网络中流经每一层, 最终生成输出 \hat{y} , 这被称为前向传播。在训练过程中, 假设损失函数是 $J(\theta)$, 则样本 (x, y) 前向传播可以产生一个损失函数 $J(y, \hat{y})$ 。反向传播算法就是使损失函数通过网络向后传播, 从而计算参数的梯度, 以此来调整网络中的参数。

对第 l 层中的参数 $W^{(l)}$ 和 $b^{(l)}$ 计算偏导数, 根据链式法则得到

$$\frac{\partial J(y, \hat{y})}{\partial W_{i,j}^{(l)}} = \left(\frac{\partial z^{(l)}}{\partial W_{i,j}^{(l)}} \right)^T \frac{\partial J(y, \hat{y})}{\partial z^{(l)}} \quad (2.6)$$

$$\frac{\partial J(y, \hat{y})}{\partial b^{(l)}} = \left(\frac{\partial z^{(l)}}{\partial b^{(l)}} \right)^T \frac{\partial J(y, \hat{y})}{\partial z^{(l)}} \quad (2.7)$$

其中, $z^{(l)} = W^{(l)} a^{(l-1)} + b^{(l)}$ 是第 l 层神经元, $a^{(l-1)}$ 是第 $l-1$ 层神经元经过激活函数的输出, 因此偏导数

$$\frac{\partial z^{(l)}}{\partial W_{i,j}^{(l)}} = \frac{\partial (W^{(l)} a^{(l-1)} + b^{(l)})}{\partial W_{i,j}^{(l)}} = \begin{bmatrix} 0 \\ \vdots \\ a_j^{(l-1)} \\ \vdots \\ 0 \end{bmatrix} \quad (2.8)$$

其中, $a_j^{(l-1)}$ 是第 i 行元素。同理可得,

$$\frac{\partial z^{(l)}}{\partial b^{(l)}} = I \quad (2.9)$$

定义第 l 层神经元的误差项为 $\delta^{(l)}$,

$$\delta^{(l)} = \frac{\partial J(y, \hat{y})}{\partial z^{(l)}} \quad (2.10)$$

$\delta^{(l)}$ 表示第 l 层神经元对最终损失的影响, 反映了第 l 层神经元对网络的贡献程度,

同时也反应了最终损失对第 l 层神经元的敏感程度。由 $z^{(l+1)} = W^{(l+1)} a^{(l)} + b^{(l+1)}$ 得,

$$\frac{\partial z^{(l+1)}}{\partial a^{(l)}} = (W^{(l+1)})^T \quad (2.11)$$

根据式 (2.5) 可得,

$$\frac{\partial a^{(l)}}{\partial z^{(l)}} = \frac{\partial f(z^{(l)})}{\partial z^{(l)}} \quad (2.12)$$

因此, 根据链式法则, 可以计算第 l 层的误差项

$$\delta^{(l)} = \frac{\partial J(y, \hat{y})}{\partial z^{(l)}} = \frac{\partial a^{(l)}}{\partial z^{(l)}} \cdot \frac{\partial z^{(l+1)}}{\partial a^{(l)}} \cdot \frac{\partial J(y, \hat{y})}{\partial z^{(l+1)}} \quad (2.13)$$

联合式 (2.10) - (2.13), 可以得到

$$\delta^{(l)} = \frac{\partial f(z^{(l)})}{\partial z^{(l)}} \cdot (W^{(l+1)})^T \cdot \delta^{(l+1)} \quad (2.14)$$

从上式可以看出, 可以通过第 $l+1$ 层的误差项计算得到第 l 层的误差项, 这就是误差的反向传播。根据式 (2.8) 和式 (2.14), 式 (2.6) 可以写作

$$\frac{\partial J(y, \hat{y})}{\partial W_{i,j}^{(l)}} = \delta_i^{(l)} a_j^{(l-1)} \quad (2.15)$$

更进一步的, 损失函数关于第 l 层权重 $W^{(l)}$ 的梯度为

$$\frac{\partial J(y, \hat{y})}{\partial W^{(l)}} = \delta^{(l)} (a^{(l-1)})^T \quad (2.16)$$

同理可得, 损失函数关于第 l 层偏置 $b^{(l)}$ 的梯度为

$$\frac{\partial J(y, \hat{y})}{\partial b^{(l)}} = \delta^{(l)} \quad (2.17)$$

通过上述公式计算出网络中每一层参数的梯度, 最后通过梯度下降法更新网络参数, 从而完成对网络的训练。

2.3 回溯线搜索

数值优化算法中经常用到线搜索求解目标函数 $f(x)$ 的最值, 线搜索是采用迭代的方式求得函数的最值。它的思想是首先计算得到一个 $f(x)$ 下降的方向, 然后确定 $f(x)$ 在这个方向上的移动步长, 最后迭代得到函数的最值。因此, 求解目标函数 $f(x)$ 的最值最重要的两点是: 求下降方向和确定步长。其中, 求下降方向的方法有很多, 如梯度下降等; 而移动步长可以使用固定值, 或者通过回溯线搜索确定。

通常优化过程采用梯度确定下降方向, 而步长 t 的确定是困难, 步长过大算法可能不收敛, 步长过小耗费的时间可能过久。为了平衡两者找到合适的步长, 可以采用回溯线搜索确定移动步长, 回溯线搜索能够使用较小的代价找到最值,

在牺牲一定精度的条件下加快计算速度，它是一种近似线搜索算法。它的主要思想是先设置一个初始步长，然后不断缩减步长大小 $t = \beta t$ ，直到满足下降条件：

$$f(x+tp) \leq f(x) + \alpha t \nabla f(x)^T p \quad (2.18)$$

其中， x 是当前点； p 是下降方向； β 是步长的缩减倍数，一般取值为 0.1~0.8； α 是控制参数，一般取值为 0.01~0.3 之间。当步长满足式 (2.18) 时，说明当前步长是合适的，避免了步长过大发生震荡，也防止了步长过小导致收敛缓慢，函数可以根据现在的步长下降。

回溯线搜索的流程如下：当前点 x ，搜索方向 p ，参数 α 、 β ，步长 $t = 1$ 。第一步，如果 $f(x+tp) > f(x) + \alpha t \nabla f(x)^T p$ ，令 $t = \beta t$ ；第二步，重复第一步，直到 $f(x+tp) \leq f(x) + \alpha t \nabla f(x)^T p$ 或者满足所设置的最大迭代次数。

2.4 本章小结

本章推导了力封闭指标的计算公式，说明了力封闭指标 ε 的意义，从而为抓取提供评估标准。本章还介绍了卷积神经网络，重点介绍了空间金字塔池化层和反向传播算法。从而在设计网络结构时加入空间金字塔池化层，使网络的输入不受图像大小的影响，反向传播算法使得我们能够计算网络输入的梯度。最后，介绍了回溯线搜索，帮助梯度下降法确定步长。

第3章 基于多级卷积神经网络的灵巧手抓取规划

如果将人类的抓取过程进行分解,发现人类抓取过程可以简单地分为以下几个步骤:发现物体、选择物体的被抓取部位、选择合适的抓取手势。为了实现多指灵巧手抓取未知物体,我们参考人类抓取过程,并结合物体抓取框和物体局部图像,提出了一种新颖的多级卷积神经网络结构。

3.1 问题分析

一般来说,抓取规划方法可以分为分析法和经验法。分析法一般根据被抓物体的形状,基于抓取质量指标,规划合适的抓取手势,将抓取问题转换为带约束的优化问题。但是,分析法大多基于精确的物体三维信息和机器人模型,而在现实环境中通常难以获取物体三维信息,这就大大限制了分析法在实际场景中的应用。现阶段在实际抓取中最常用的抓取规划方法是经验法,经验法是在仿真机器人或真实机器人中已存在的抓取经验的基础上,通过机器学习的方法实现抓取规划。经验法在未知物体的实际抓取上效果显著,但经验法主要还是用于简单夹持器的抓取规划,只有少量的工作将深度学习用于难度更大的多指灵巧手抓取。针对上述的问题,本章将平行夹持器抓取规划算法中的物体抓取框与灵巧手手掌联系起来,设计了一种新颖的多级卷积神经网络结构。通过物体 RGB-D 图像确定多指灵巧手的抓取位形,实现多指灵巧手抓取未知物体。

3.2 抓取框的定义

灵巧手抓取过程中需要确定物体的被抓取部位,通过被抓取部位确定灵巧手的抓取位姿。本文使用抓取矩形框表示物体的被抓取部位,同时也表示灵巧手手掌相对于物体的位姿。采用 Jiang^[34]等人 and 喻群超等人^[43-44]的方法定义抓取矩形框,抓取矩形框的定义表示如图 3.1 所示。




图 3.1 抓取框

使用符号 g 表示抓取矩形框， g 可以定义为：

$$g = \{x, y, h, w, \theta\} \quad (3.1)$$

其中， x 、 y 表示抓取矩形框的中心位置， w 、 h 表示抓取矩形框在图像中的长和宽，决定框的大小； θ 是 w 与图像中的竖直向量 p 的夹角，可以确定手掌相对于物体的姿态。结合位置 (x, y) 和旋转角 θ ，从物体图像中裁剪出抓取框区域的图像，将其作为物体被抓取部位的图像。已知物体在图像中的位置 (x, y) ，可以通过深度相机确定抓取框中心在相机坐标系中的位置，再根据坐标转换关系和手掌中心与抓取框中心的距离，从而确定手掌中心相对于物体的位置。

3.3 多级卷积神经网络结构设计

模仿人类抓取过程，结合抓取框和物体图像思想，本文设计一种新颖的卷积神经网络结构，用来预测灵巧手对未知物体的抓取手势。整个卷积神经网络在结构上分为四级，各级卷积网络实现不同的功能。第一级网络定位物体在图像中的大致区域，确定抓取框的搜索范围。第二级网络在第一级网络的基础上，搜索得到可用的预选抓取框。第三级网络准确评估所得到的预选抓取框，获得最佳抓取框，确定灵巧手手掌相对于物体的位姿，实现灵巧手接近物体的过程。第四级网络通过第三级网络所获得的最佳抓取框区域的深度图，预测灵巧手的抓取手势，达到灵巧手抓取未知物体的目的。四级卷积神经网络的整体结构如图 3.2 所示，根据网络的功能将多级卷积网络分为抓取框检测网络和多指灵巧手抓取手势预测网络，前三级网络组成抓取框检测网络，最后一级定义为抓取手势预测网络。

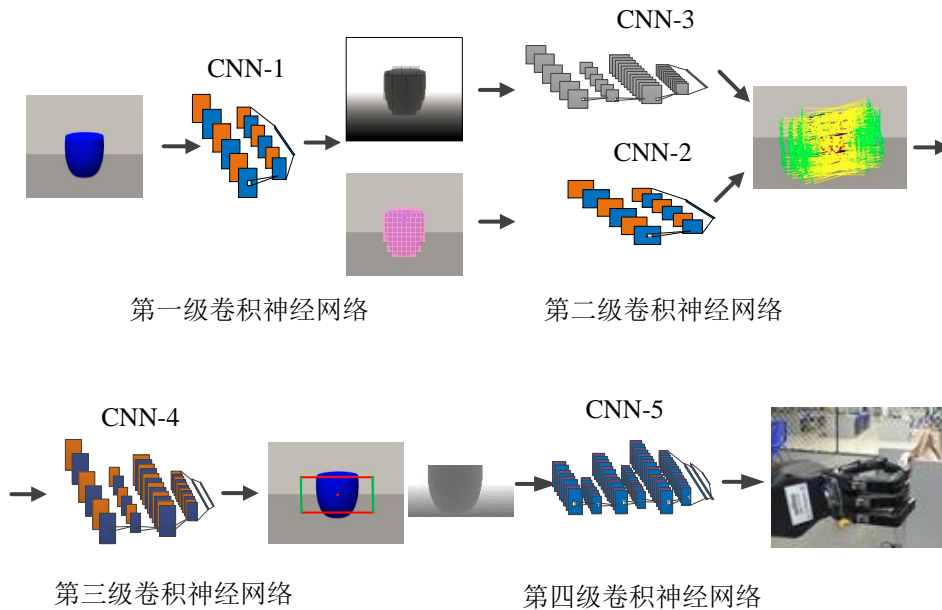


图 3.2 多级卷积神经网络整体结构图

3.3.1 第一级网络结构

第一级卷积神经网络 CNN-1 用于在图像中标记物体存在区域，网络结构由两层隐含层和一层输出层组成，如图 3.2 所示。输入图像首先通过一层卷积层，一共 6 个卷积核，卷积核大小为 3×3 ，步进大小为 1×1 。接着，通过一层空间金字塔池化层，该层使得任意大小的特征图都能够转换成固定大小的特征向量，使得后续的全连接层不受网络输入图像大小变化的影响。最后，通过一层只有单一神经元的输出层，网络的输出结果是 0-1，用于判断输入图像中是否存在物体图像。

网络采用滑动窗口的方式进行搜索，即将网络的输入图像分割成一块块小图像，再通过网络预测小图像中是否存在物体，从而确定物体在完整图像中的大致区域，为后续网络提供搜索范围，提高网络的运行效率。

3.3.2 第二级网络结构

第二级网络中的 CNN-2 同样包含两层隐藏层和一层输出层，如图 3.2 所示。第二级卷积神经网络在上级网络的基础上搜索抓取框，在物体可能存在的区域内选择某一点作为抓取框的中心点，并选择抓取框的大小和角度，最后裁剪出抓取框的图像作为网络的输入。图像输入经过卷积核个数为 6、卷积核大小为 3×3 的卷积层。接着，采用空间金字塔池化层进行特征图处理，之所以采用空间金字塔池化层，是由于抓取框大小的改变使得网络输入图像时刻变化。最后通过只有一个神经元的输出层，网络的输出结果是 0-1，用于判断此次抓取框的合理性。

第二级网络中 CNN-3 用于处理深度图像，图像处理过程与 CNN-2 一致，只不过网络结构不同。第一层为输入层；第二层是卷积核个数为 6、卷积核大小为 5×5 的卷积层；第三层是平均池化层；第四层是卷积核个数为 12、卷积核大小为 3×3 的卷积层；第五层是空间金字塔池化层；第六层为网络的输出层，网络的输出结果同样为 0-1。

只有当 CNN-2 和 CNN-3 对于同一个抓取框的判断都大于 0.5 时，这个抓取框才被认为是有效的，从而作为下一级网络的输入。

3.3.3 第三级网络结构

第三级卷积网络 CNN-4 对上一级得到的预选抓取框进行更加精确的评判。网络的卷积层结构与 CNN-3 一样，最后通过两层全连接层，全连接层的神经元数量分别为 24 和 1，网络的输出为 0-1，网络结构图如图 3.2 所示。将所有预选

抓取框的输出结果进行排序，得分最高的抓取框即为最优抓取框，截取最优抓取区域的深度图作为下一级网络的输入。

3.3.4 第四级网络结构

第四级卷积网络 CNN-5 的网络结构如图 3.2 所示，包含输入、输出层在内共十层。网络的输入是第三级网络获得的抓取框区域的深度图，之所以只考虑抓取框区域的深度图，是因为灵巧手的抓取手势只与物体被抓部位的形状有关，与物体其他部位以及物体颜色都无关。第二至七层由卷积层和池化层交错组成：卷积核的大小为 3×3 ，卷积核的个数分别为 16、32 和 64；池化层采用最大池化层，核大小和步进大小均为 2×2 。第八、九层为全连接层，每层均有 200 个神经元。第十层为整个网络的输出层，输出特征向量大小对应灵巧手的关节数量，可以根据不同灵巧手的关节数量调整输出层。CNN-5 比前面的网络具有更大的规模以提取更多的特征，因此它可以近似物体的被抓取部分与多指灵巧手抓取手势之间的关系。

综上所述，五个卷积神经网络组成灵巧手多级抓取网络。多级抓取网络将任务细化，明确了各级网络的功能，可以大大减少网络的搜索时间。依据网络功能的不同，多级抓取网络可以分为两部分。一部分是前三级网络称为抓取框检测网络，另一部分是最后一级网络称为抓取手势预测网络。另外，整个网络的主要目标是物体的被抓取区域到多指手抓取手势的映射，这很符合人类的抓取经验。

3.4 灵巧手手掌位姿的确定

多级抓取网络的最终输出是灵巧手的抓取手势，然而抓取过程还包含灵巧手接近物体的过程。因此，要完成抓取任务还需灵巧手手掌相对于物体的位姿。正如前文提及的，我们将抓取框视为灵巧手手掌。因此，通过抓取框相对于物体的位姿，可以得到灵巧手手掌相对于物体的位姿。

通过相机可以直接获得视角内的彩色图像以及点云数据，将彩色图像与点云数据进行匹配，就能知道包括抓取框中心点在内的每个图像像素点在相机坐标系中的 3D 值。由于抓取框中心与手掌中心的距离 Δd 为 0.03m，所以可以得到手掌中心在相机坐标系中的 3D 值。通过坐标系转换，将手掌中心点坐标转换到世界坐标系中：

$${}^w\mathbf{p} = {}^w\mathbf{T}_c {}^c\mathbf{p} \quad (3.2)$$

其中 ${}^w\mathbf{p} = [{}^wx \quad {}^wy \quad {}^wz]^T$ 和 ${}^c\mathbf{p} = [{}^cx \quad {}^cy \quad {}^cz]^T$ 分别是手掌中心点在世界坐标系和相机坐标系中的位置， ${}^w\mathbf{T}_c$ 是转换矩阵。

灵巧手从初始姿态到最终姿态的旋转过程如图 3.3 所示，图中旋转过程只是示意图，实际实验时是直接计算得到最终姿态。首先，灵巧手根据最优抓取框的旋转角度 θ ，到达与抓取框相同的姿态。接着，为了确保抓取成功，我们还考虑了物体表面倾斜度。通过选取物体表面上抓取中心附近不位于同一条直线上的三个点，构建一个物体表面平面，如图 3.3 所示。由三点坐标计算物体倾斜平面法向量 \mathbf{n}_1 ，再求解平面法向量 \mathbf{n}_1 与竖直平面法向量 \mathbf{n}_2 的夹角余弦值，最后求解反余弦值，得到平面倾斜度 α ：

$$\alpha = \arccos \frac{\mathbf{n}_1 \cdot \mathbf{n}_2}{|\mathbf{n}_1| |\mathbf{n}_2|} \quad (3.3)$$




图 3.3 手掌从初始姿态旋转到最终姿态

由旋转角 θ 和倾斜角 α ，进一步计算得到最终手掌坐标系 P_f 相对于初始手掌坐标系 P_0 的旋转矩阵 ${}^{P_0}R_{P_f}$ 。初始手掌坐标系相对于世界坐标系的旋转矩阵 ${}^W R_{P_0}$ 是固定的，通过矩阵相乘可以得到最终手掌坐标系相对于世界坐标系的旋转矩阵为

$${}^W R_{P_f} = {}^W R_{P_0} {}^{P_0} R_{P_f} \quad (3.4)$$

${}^W R_{P_f}$ 是最终手掌坐标系相对于世界坐标系的旋转矩阵，结合位置公式 (3.2)，得到手掌相对于世界坐标系的位姿，通过运动学反解计算机械臂的关节值，最后发布位置指令驱动末端执行器接近物体。

3.5 基于多级网络的抓取模型

根据多级抓取网络的通用结构和 Shadow Hand Lite 灵巧手的结构特点，提出基于多级卷积神经网络的 Shadow Hand Lite 灵巧手的抓取规划模型。由于 Shadow Hand Lite 的关节数是 16，故将抓握手势预测网络的输出层神经元个数设为 16。使用修改后的多级抓取网络进行未知物体抓取。首先，从物体图像中获取最优抓取框：

$$g = G(I) \quad (3.5)$$

其中, $G(\bullet)$ 是抓取框检测网络, I 是物体的 RGB-D 图像, g 是检测得到的最优抓取框。根据抓取框 g 的中心位置 (x, y) 和旋转角度 θ , 从物体深度图中截取抓取框区域的深度图 d :

$$d = C(x, y, \theta) \quad (3.6)$$

其中, $C(\bullet)$ 是图像截取函数。将深度图 d 作为抓取手势预测网络的输入, 预测灵巧手的抓取手势:

$$c = P(d) \quad (3.7)$$

其中, $P(\bullet)$ 是抓取手势预测网络; c 是一个 16 维的向量, 表示 Shadow Hand Lite 灵巧手的抓取手势。与此同时, 根据 3.4 节的灵巧手位姿计算过程, 计算得到灵巧手的位姿 p 。最后, 结合灵巧手位姿 p 和灵巧手的抓取手势 c , 完成灵巧手抓取未知物体任务 $T(p, c)$ 。

3.6 数据集生成与网络训练

多级卷积神经网络根据功能分为两部分, 训练网络的数据集也因此分成两部分: 抓取框检测网络使用的数据集是美国康奈尔大学提供的抓取数据集^[56]; 抓取手势预测网络使用的数据集是我们自己制作的。

3.6.1 抓取框检测网络数据集



图 3.4 抓取框数据集

抓取框检测网络所使用的数据集包含两个部分, 一部分是图像中没有抓取物的背景图像, 另一部分是图像中拥有抓取物的图像, 并标记有抓取框, 如图 3.4 所示。

3.6.2 抓取手势预测网络数据集

该网络数据集的生成过程是一个多阶段过程，并且数据的采集过程是在实际机器人上进行的。第一步，通过 Kinect v2 相机采集物体的彩色图像和点云数据，并且物体摆放位姿各不相同，以增加数据集的多样性。图像数据集中同样也包含没有物体的背景图片，用来消除背景图像的影响。第二步，拖动灵巧手抓取物体，记录灵巧手手掌相对于物体的位姿以及灵巧手的关节角数据。第三步，根据上一步所记录的手掌相对于物体的位姿，裁剪出物体上相应区域的深度图。通过上述的三步骤，得到预抓取手势预测网络的训练数据集，图 3.5 是数据集中的部分被抓取物体。数据集包含两个部分：一部分是物体抓取部位的局部图像以及背景图；另一部分是与局部图像对应的灵巧手关节角数据。




图 3.5 物体被抓取部位深度图

3.6.3 网络训练

灵巧手多级抓取网络的训练是分开的，单独训练抓取框检测网络和灵巧手抓取手势预测网络，两者的训练过程大致相同。其中，抓取手势预测网络将 MSE (Mean squared error) 损失函数作为网络的损失函数：

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - y_i^p)^2 \quad (3.8)$$

其中， y_i 是网络的预测值， y_i^p 是真实值， n 是样本数目。本章通过批量梯度下降法进行优化训练，采用 Adam 优化器，批量大小为 8，迭代次数为 5000 次。在网络训练之前，将网络输入的深度图进行归一化，使得它们的值均在 0-1 之间。将采集得到的数据集随机分为两部分，其中 80% 的数据作为训练数据，另外的 20% 数据作为验证集数据。在网络训练过程中，设置学习速率为 0.001，并且保证每次迭代训练完成后训练数据集的顺序被打乱。为了防止网络过拟合，采用早停技术，当网络的验证集误差不再下降时保存网络的参数。

3.7 实际实验

本文通过两方面的实验对多级卷积神经网络进行验证。一个是在实际环境中进行多指灵巧手抓取实验；另一个是通过 GraspIt! 对所生成的抓取手势进行评估。

3.7.1 抓取实验与结果

本文用于抓取实验的机器人系统是由 Shadow Hand Lite 灵巧手和 UR5 机械臂组成的拟人手臂系统。灵巧手具有 16 个关节，UR5 具有 6 个关节。灵巧手型号为 G1M4R，指尖有压力传感器。对于物体图像的采集，本文使用微软公司的 Kinect v2 相机，Kinect2.0 具有彩色摄像头和深度摄像头，能够提供物体的 RGB 图像和点云数据。整个系统通过机器人操作系统 (ROS) 进行通信，完整的实验平台如图 3.6 所示。




图 3.6 实验平台

多指灵巧手完整的抓取过程如图 3.7 所示，抓取框检测网络用来检测物体上的最佳抓取部位，确定灵巧手相对于物体的位姿，并在深度图上将抓取框区域的图像裁剪下来作为抓取手势预测网络的输入。紧接着，抓取手势预测网络实现从物体最佳抓取部位图像到抓取手势的映射。将两者结合在一起，实现拟人手臂系统的自主抓取

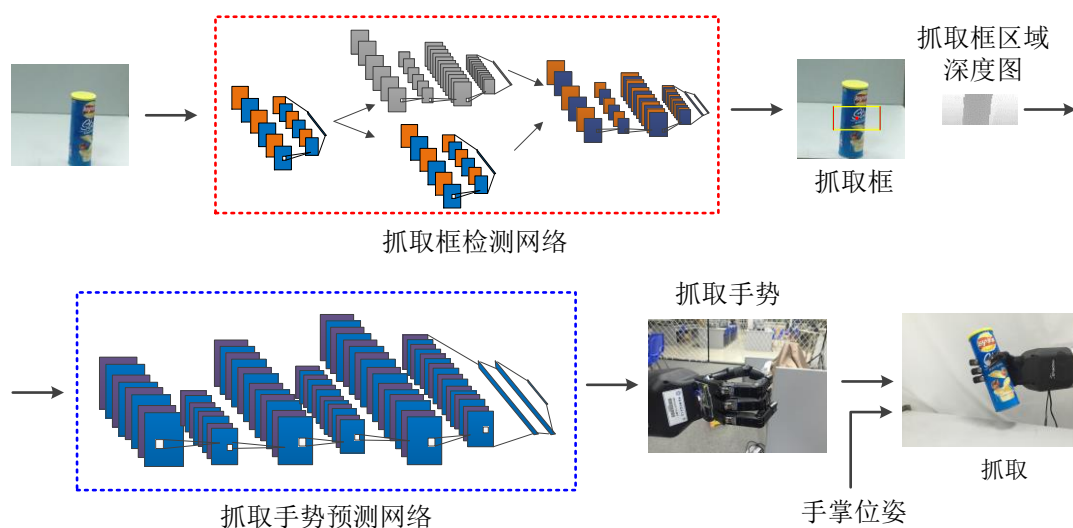


图 3.7 多指灵巧手的抓取过程示意图




图 3.8 多指灵巧手实际抓取过程

如图 3.8 所示实验过程分为四个阶段：1)、Kinect v2 相机获取物体 RGB-D 图像信息，将图像信息输入到网络中，得到物体上的抓取框以及抓取手势。2)、根据抓取框，计算灵巧手手掌相对于物体的位姿，规划机械臂接近物体，达到灵巧手接近物体的目的。3)、当灵巧手接近物体时，根据网络输出得到的预抓取手势，使灵巧手达到指定手势。4)、最后闭合灵巧手，通过指尖的压力传感器判断手指是否与物体接触，接着举起物体并维持 5 秒钟以检测抓取是否成功。

抓取实验从测试集中一共选择了 6 个物体，考虑不同的日常物体以及同一物体的不同位姿，对多级网络进行测试。对每个物体进行 10 次抓取实验且每次抓取实验中物体的位姿都不相同，抓取成功率如表 3.1 所示，部分抓取结果如图 3.9 所示。

表 3.1 实际抓取实验的抓取成功率

物体	成功率	物体	成功率
漏斗	6/10	工具箱	9/10
墨粉盒	10/10	瓶子	10/10
零食盒	8/10	薯片筒	10/10




图 3.9 部分抓取结果

从表 3.1 可以看出,通过多级网络,灵巧手对其中 5 个物体的抓取成功次数都达到了 8/10 以上。其中更有 3 个物体的抓取成功率达到了 10/10,抓取成功率很高,只有一个物体因为表面光滑等原因使得抓取困难,成功次数只有 6/10。通过抓取实验可以看出,本文所设计的网络结构能够成功地与多指灵巧手结合完成物体抓取。同时验证了抓取手势预测卷积神经网络的泛化能力,能够预测未知物体的抓取手势,从而实现对未知物体进行精细抓取。

3.7.2 抓取质量评估

抓取质量的评估工作一直都是抓取规划的研究重点。分析法自带抓取评估指标,大多数的经验法也使用经典的指标。但自从经验法引入深度学习后,评估抓取规划算法的指标大多为抓取成功率。一般性抓取,可以用抓取成功率,但对于多指灵巧手这种精确抓取,应该考虑更严格的定量评估方法,即力封闭指标。因此,本文使用力封闭指标评估抓取质量,整个评估工作在仿真环境 GraspIt!^[27]中进行。GraspIt!是哥伦比亚大学机器人研究小组开发的一个分析抓取质量和规划的仿真环境。它可以作为抓取规划算法的测试平台,能提供一个交互式模拟环境,导入各种各样的灵巧手和物体模型,并且评估由这些灵巧手所形成的抓取。因此,本文使用它对多级抓取网络生成的抓取手势进行评估,在仿真中对实际抓取过程进行评估,计算力封闭指标,从而实现量化抓取质量的目的。

表 3.2 抓取质量评估结果

方法	长方体	圆柱体	漏斗
GraspIt!	0.0758	0.0684	0.1706
本文方法	1	0.1063	0.0617
	2	0.0882	0.0513
	3	0.0809	0.0390
	4	0.0885	0.0419
	5	0.0957	0.0344
	6	0.0484	0.0721
	7	0.0581	0.0828
	8	0.2064	0.1039
	9	0.0775	0.0667
	10	0.0809	0.0727
			0.1364

本文还与 GraspIt!中自带的物体抓取规划方法进行了对比实验。GraspIt!中的方法是在已知物体的完整三维信息和灵巧手模型信息的基础上搜索最优抓取手

势^[22]，虽然它能够生成高质量的抓取手势，但是难以应用在未知物体抓取中。在对比评估过程中，第一步是将实际实验中所生成的抓取手势导入到 GraspIt! 中计算力封闭指标，第二步是根据公式 (2.1) - (2.3) 计算力封闭指标，这一计算过程由 GraspIt! 自动计算得到。GraspIt! 中搜索最优抓取手势是对物体全方位进行的，而这在实际抓取中是不现实的，因为实际抓取会受物体的遮挡和视角限制等原因的影响。因此，必须要在 GraspIt! 中限制搜索范围，使它与我们的抓取方法保持一致，均从物体的正前方进行抓取，创建一个公平的比较环境。

对三个不同的物体进行 10 次抓取，抓取的力封闭指标 ε 结果如表 3.2 所示。在 GraspIt! 中 $\varepsilon = -1$ 表示当前抓取位形未形成力封闭。对于力封闭抓取， ε 的取值范围为 0~1 且越接近 1 表明当前抓取越稳定，但实际抓取中 ε 一般都小于 0.1。由于实验中物体是随机放置的，故生成的抓取框和抓取手势受实际环境影响，导致同一物体的 10 次抓取质量结果变化较大。从抓取质量评估结果表 3.2 可以看出，本文所提方法生成的抓取与 GraspIt! 生成的抓取不相上下，表明本文的方法媲美于 GraspIt! 自身的抓取规划方法。

3.8 本章小结

本章从人类抓取经验中获取灵感，结合抓取框和物体局部图像思想，设计了一个新颖的多级卷积网络，在多指灵巧手上实现了未知物体的抓取。在实际机器人上的抓取实验表明多级抓取网络可以为多指灵巧手提供高质量的抓取手势，并且未知物体的实际抓取成功率最低 60% 最高 100%，证明了多级抓取网络的实用性。除此之外，本章还在 GraspIt! 中使用力封闭指标评估抓取手势。在仿真评估实验中，展示了多级抓取网络生成的抓取不弱于 GraspIt! 自身规划算法所生成的抓取。

第4章 灵巧手的改进型抓取手势预测网络

多级抓取网络的提出，实现了多指灵巧手抓取未知物体，其中抓取手势预测网络实现了从物体被抓部位图像到灵巧手抓取手势的映射。但是这一抓取过程中也忽略了一些重要信息：未考虑到抓取时手掌的位姿，以及物体被抓取部位没有物体的厚度信息等。本章针对这些问题，改进了原有抓取手势预测网络，提升网络的性能和实用性，从而完善多指灵巧手抓取未知物体的过程。

4.1 问题分析

在前面的第三章中，本文设计了一种抓取手势预测网络，该网络以物体被抓取部位图像作为输入，灵巧手的抓取手势作为输出，实现了多指灵巧手抓取未知物体。虽然抓取实验的结果较好，但也存在一些之前未考虑到的问题。当灵巧手以不同手掌姿态抓取物体的同一部位时，由于灵巧手抓取的是物体同一部位，使得物体被抓取部位图像一样，最后经过抓取手势预测网络得到的手势也一样，这与人类抓取经验相违背。以不同的手掌姿态抓取同一部位应该需要不同的抓取手势，如图4.1所示，三次抓取都是抓取物体的同一部位，但每次抓取的手掌姿态都不一样，最终抓取手势也各不相同。




图 4.1 不同位姿下的灵巧手抓取




图 4.2 长方体整体深度图和抓取框区域的深度图

第三章中的抓取手势预测网络只考虑了物体被抓取部位的图像,当被抓取物体是长方体类物体时,被抓取部位的图像无法提供物体的厚度信息,如图4.2所示。左图是物体整体深度图,右图是物体被抓取部位的深度图,可以看出右图缺少物体的厚度信息,而这必然会影响抓取手势的预测。此外,在第三章中抓取手势预测网络的数据集是通过人工采集得到的,因此灵巧手抓取手势的好坏并没有一个定量标准,只依据人为的评判,导致数据集的质量可能不是很好。除此之外,人为采集过程费时费力,无法生成大规模的数据集。为了解决上述问题,本章改进了抓取手势预测网络的结构,并且在仿真环境中生成具有力封闭的抓取位形数据集。

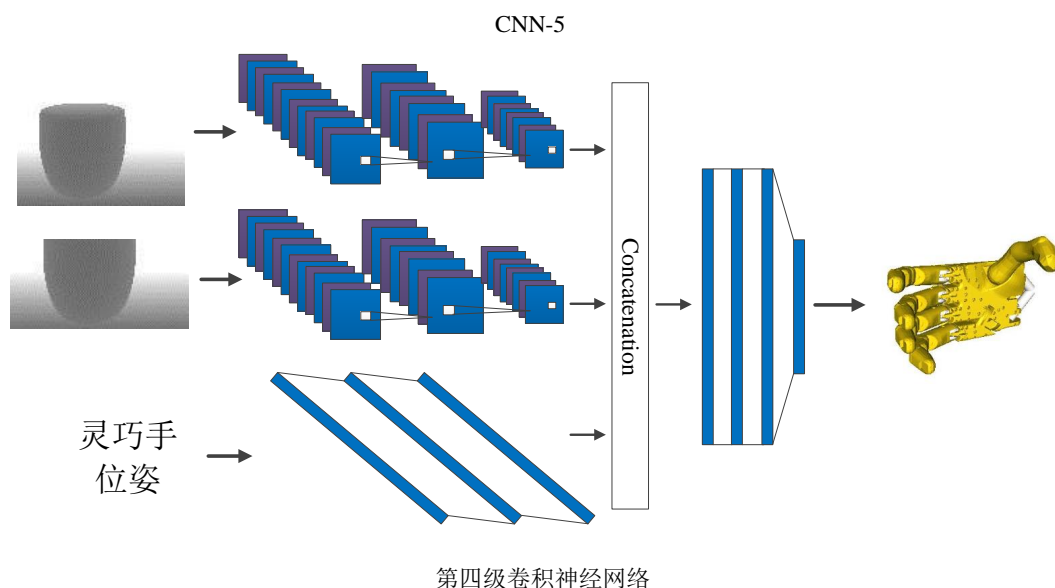


图 4.3 改进型灵巧手抓取手势预测网络

4.2 改进型抓取手势预测网络

改进型灵巧手抓取手势预测网络的结构如图4.3所示,网络将物体的整体深度图、抓取框区域的深度图以及灵巧手手掌的抓取位姿作为输入,将灵巧手的抓取手势作为输出。本章提取物体附近的 128×128 的整体深度图作为网络输入之一,由于相机位置通常高于物体抓取平台位置,因此物体的整体深度图能够提供物体的厚度信息。加入物体的整体深度图,能够弥补长方体类的物体在抓取框区域的深度图中厚度信息的缺失,如图4.2所示。网络的另一个图像输入是抓取框区域的深度图,该图像由抓取框检测网络获取得到,抓取框区域的深度图被视为物体的被抓取部位以及灵巧手的抓取位置。因为抓取手势与抓取部位的形状息息相关,而又不需要考虑物体的颜色,所以选择抓取框区域的深度图作为网络输入之一。网络的最后一个输入是灵巧手手掌的抓取位姿。显而易见,当灵巧手抓取同一物

体的同一部位，不同的手掌位姿需要不同的抓取手势，如图 4.1 所示。本章选择灵巧手手掌相对于物体坐标系的位姿，而不是相对于其他固定坐标系的位姿，比如：世界坐标系。之所以这样是因为当多次抓取同一物体的同一部位但物体发生移动时，可以保证网络输入的灵巧手位姿不会发生变化，从而使网络预测的灵巧手抓取手势保持一致。与一般的位姿表示不同，本章考虑了手掌距离物体坐标系 XOY 平面的 d 值以及手掌姿态的四元数 $xyzw$ ，如图 4.4 所示。本文之所以采用这样的表示有以下两点原因：第一，手掌相对于物体的位置 xy 信息已经包含在抓取框区域的深度图中，抓取框区域的深度图正是根据手掌的抓取位置 xy 获取到的；第二，在实际实验中，由于物体的随机摆放，无法及时获取物体坐标系，这样也就无法及时获取手掌坐标系相对于物体坐标系的 xy 信息，如图 4.5 所示。虽然可以通过棋盘格标定板获取物体坐标系，但需要每随机摆放一次物体就标定一次，这明显不适用于实际抓取。




图 4.4 灵巧手相对于物体坐标系的位姿图




图 4.5 物体坐标系

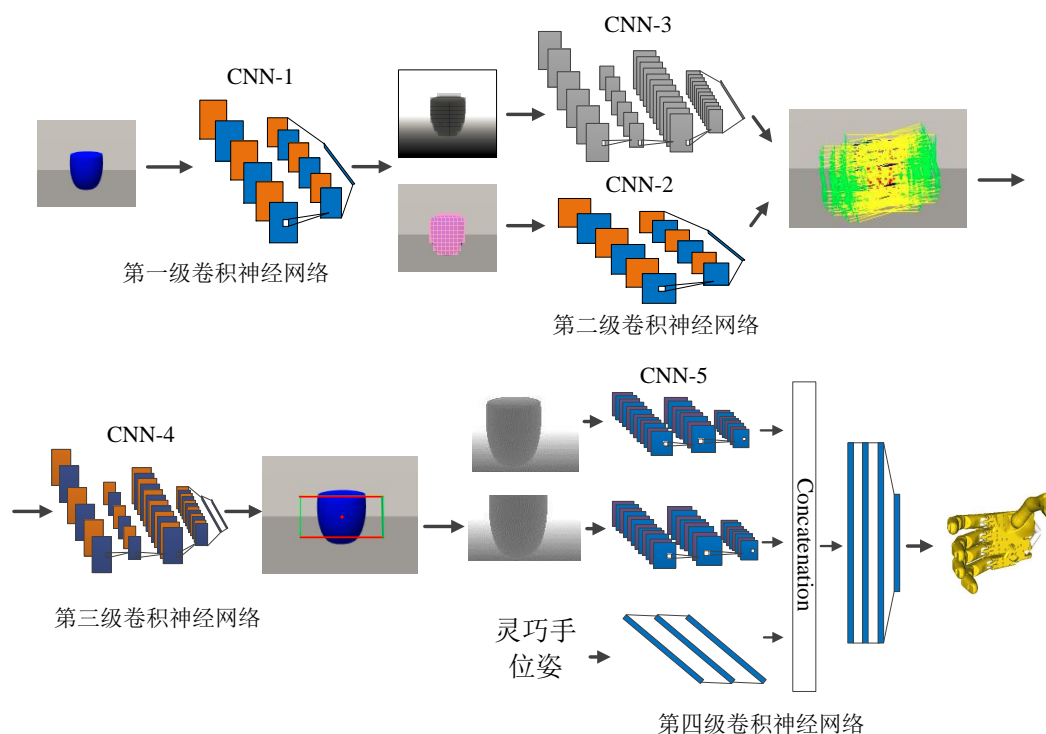


图 4.6 多级抓取网络

物体的整体深度图通过两层卷积层以及一层最大池化层，两层卷积层的核大小分别为 12×12 和 6×6 ，步进大小为 2×2 。最大池化层的核大小和步进大小均为 2×2 。抓取框区域的深度图也通过一样结构的网络层，只不过卷积层的核大小分别为 6×6 和 3×3 。灵巧手手掌的抓取位姿则通过三层全连接层，每层均有 32 个神经元。最后将三者的输出连接在一起通过四层全连接层，前三层全连接层均有 256 个神经元。最后一层为整个网络的输出层，输出神经元个数对应灵巧手的关节数量，可以根据不同灵巧手的关节数量调整输出层。

将改进的抓取手势预测网络替换原先的抓取手势预测网络，组成新的灵巧手多级抓取网络，整体网络结构图如图 4.6 所示。同第三章一样，前三级为抓取框检测网络，最后一级为抓取手势预测网络。

4.3 灵巧手手掌位姿的确定

抓取过程需要灵巧手接近物体，规划接近轨迹需要灵巧手在世界坐标系下的最终位姿，同时抓取手势预测网络的输入也需要灵巧手在物体坐标系下的位姿，因此我们需要计算最终抓取时刻灵巧手分别在世界坐标系和物体坐标系下的位姿。灵巧手从初始姿态到最终姿态的旋转过程如图 3.3 所示，因此根据式 (3.2) 和式 (3.4) 得到最终手掌坐标系相对于世界坐标系的位姿。通过运动学反解计算机械臂的关节值，最后发布位置指令驱动末端执行器接近物体。

由于物体抓取平台固定，因此物体坐标系在相机坐标系中的 z 值是固定的。再根据抓取框中心点的 z 值以及抓取框中心与手掌中心的距离 $\Delta d = 0.03\text{m}$ ，从而求得手掌距离物体坐标系 XOY 平面的 d 值：

$$d = z_o - z_g + \Delta d \quad (4.1)$$

其中， z_g 、 z_o 分别是抓取框中心点和物体坐标系在相机坐标系下的 z 值。

初始手掌坐标系相对于物体坐标系的旋转矩阵 ${}^O_{P_0}\mathbf{R}$ 是固定的，通过矩阵相乘可以得到最终手掌坐标系相对于物体坐标系的旋转矩阵为

$${}^O_{P_f}\mathbf{R} = {}^O_{P_0}\mathbf{R} {}^{P_0}_{P_f}\mathbf{R} \quad (4.2)$$

其中， ${}^{P_0}_{P_f}\mathbf{R}$ 是最终手掌坐标系 P_f 相对于初始手掌坐标系 P_0 的旋转矩阵。最后，将 ${}^O_{P_f}\mathbf{R}$ 转换为四元数作为抓取手势预测网络的输入之一。

4.4 基于多级网络的抓取模型

同第三章一样，将改进型抓取手势预测网络的输出层神经元个数设为 16，使得通用型多级抓取网络适用于 Shadow Hand Lite 灵巧手。使用修改后的多级抓取网络进行未知物体抓取。首先，从物体图像中获取最优抓取框 g 。接着，根据抓取框 g 的中心位置 (x, y) 和旋转角度 θ ，从物体深度图中截取抓取框区域的深度图 d 。同时，根据 4.3 节的灵巧手位姿计算过程，计算得到灵巧手相对于世界坐标系的位姿 ${}^w p$ 和灵巧手相对于物体坐标系的位姿 ${}^o p$ 。将物体整体深度图 I 、抓取框区域深度图 d 和位姿 ${}^o p$ 作为改进型抓取手势预测网络的输入，预测灵巧手的抓取手势：

$$c = P(I, d, {}^o p) \quad (4.3)$$

其中， $P(\bullet)$ 是改进型抓取手势预测网络； c 是一个 16 维的向量，表示 Shadow Hand Lite 灵巧手的抓取手势。最后，结合灵巧手位姿 ${}^w p$ 和灵巧手的抓取手势 c ，完成灵巧手抓取未知物体任务 $T({}^w p, c)$ 。

4.5 数据集的生成

为了解决人工采集数据费时费力的问题以及消除人为主观评判的影响，本章中的数据集是在仿真软件 GraspIt! 中生成的。通过 GraspIt! 生成抓取位形，由于它自带的抓取规划算法是基于力封闭指标的，因此我们能够从中筛选出高质量的抓取位形。本章训练抓取手势预测网络学习力封闭的抓取手势，从而确保抓取规划方法不仅具备深度学习的实用性，还能生成与分析法不相上下的高质量抓取。抓取手势预测网络数据集的生成过程是一个多阶段过程。第一步，从 KIT database 模型库^[57]中选择合适的物体，本章一共选择了 65 个适合抓取的物体模型。第二步，将物体模型导入仿真环境 GraspIt! 中，每个模型的载入都伴随着一个 Shadow Hand Lite 模型，如图 4.7 所示。通过 GraspIt! 自带的抓取规划器，生成抓取数据，抓取数据包含灵巧手相对于物体的位姿数据以及灵巧手的关节数据，从位姿数据中提取抓取手势预测网络的位姿输入数据。本文一共生成 1039 个抓取示例，均满足力封闭要求。第三步，将每个模型物体导入 Gazebo 中，获取物体的深度图。在原有深度图的基础上获取物体的整体深度图 128×128 ，最后结合 GraspIt! 生成的抓取数据中的灵巧手位姿数据生成物体被抓取部位的深度图 64×128 。完整的数据生成示意图以及部分抓取数据集，如图 4.7 所示。

数据生成算法如图 4.8 所示，算法的输入是物体模型数据、模型数量以及灵巧手在 GraspIt! 中的初始位姿，输出是抓取位形数据和物体被抓部位深度图。首先，将物体模型载入 GraspIt! 和 Gazebo 中，在 GraspIt! 中设置灵巧手的初始位姿并开始规划抓取，在 Gazebo 中获取物体深度图；接着，筛选规划得到的抓取，

剔除非力封闭的抓取；之后，根据筛选后的抓取位形和物体深度图，截取物体被抓取部位的深度图；最后，保存抓取位形数据和物体被抓取部位深度图。

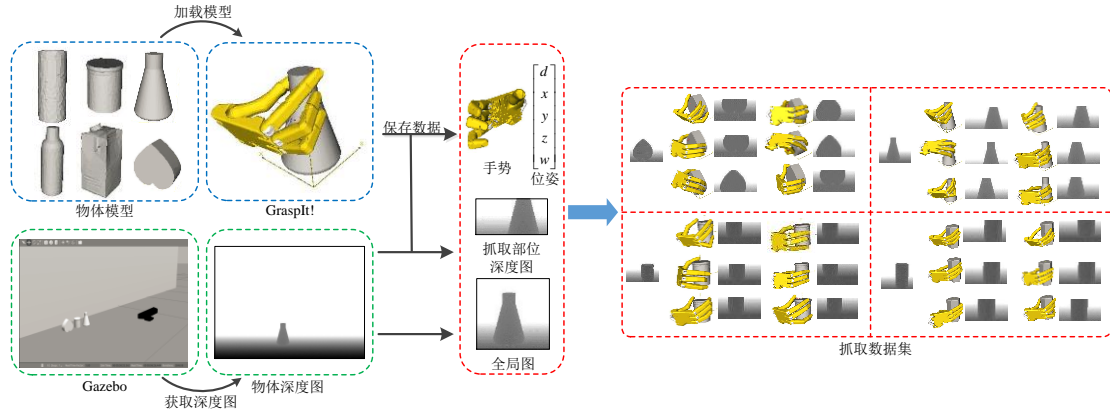


图 4.7 数据生成示意图

算法 4.1 数据生成算法

Data: 物体模型数组, M ; 物体模型数量, m ; 灵巧手初始位姿数组, H ;

Result: 抓取数据, G ; 物体被抓取部位深度图, P ;

```

1 for  $i = 1 \dots m$  do
2   将物体模型  $M[i]$  载入 GraspIt! 和 Gazebo;
3   在 GraspIt! 中设置灵巧手的初始位姿  $H[i]$ ;
4   进行抓取规划  $G = \text{planGrasps}()$ ;
5   获取物体深度图  $D$ ;
6   for each grasp  $g$  in  $G$  do
7     if  $g$  is not force closure then
8       删除  $g$ ;
9     end
10    截取抓取部位深度图  $P = \text{getPatch}(D, g)$ ;
11    保存深度图  $P$ ;
12  end
13  保存抓取数据  $G$ ;
14 end

```

图 4.8 数据生成算法

通过上述的过程，得到抓取手势预测网络的训练数据集。数据集包含以下几个部分：物体的整体深度图、物体被抓取部位的深度图、灵巧手相对于物体的位姿以及对应的灵巧手关节角数据，部分数据集如图 4.7 所示。

4.6 仿真实验结果

本节通过仿真实验对所提出的抓取规划方法进行验证。仿真实验是在仿真环境 GraspIt!中进行的，实验中的多指灵巧手是 Shadow Hand Lite，测试对象是4个最常见形状的未知物体，杯子、圆柱体、长方体以及圆锥体，每个物体抓取10次。

首先，我们通过 GraspIt!生成测试物体的抓取，这样做有两点好处：1、在灵巧手抓取位姿相同的前提下，比较不同规划方法生成的抓取位形。2、GraspIt!得到的抓取位姿能够确保灵巧手抓取物体，避免因位姿原因，比如：手掌距离物体过远或手掌未朝向物体，导致灵巧手抓取失败。仿真实验过程与上文的数据集生成过程类似，从抓取数据中提取抓取手势预测网络输入所需的位姿信息。接着在 Gazebo 中获取物体的全局深度图和物体被抓取部位的深度图。最后将抓取手势预测网络预测的抓取手势导入 GraspIt!中并计算抓取质量。

4.6.1 网络结构合理性验证

为了验证抓取手势预测网络结构的合理性，我们先进行了两组仿真实验。第一组仿真实验将抓取杯子的灵巧手位姿用于圆锥体，这样保证网络的位姿输入一致而图片输入不同。第二组仿真实验则是将圆锥体的某一抓取位置固定，得到相同的图片输入，再旋转灵巧手得到不同的位姿输入。




图 4.9 第一组仿真实验结果图

(1) 第一组仿真实验

将 GraspIt! 对杯子生成的抓取位姿用于圆锥体，通过抓取位姿生成圆锥体的被抓取部位深度图，一共进行三次抓取实验，如图 4.9 所示，图中第一行是三次实验中杯子和圆锥体的抓取区域深度图。图中的每一列是一次抓取实验，同一列的抓取位姿是相同的，不同列的抓取位姿是不同的。图中第二列是灵巧手处于位姿 1 的情况下，分别对圆锥体和杯子进行抓取的实验结果，第三、四列是处于位姿 2、3 情况下的抓取实验。

可以从实验结果图中看出，在相同位姿情况下，不同物体的抓取手势都有很大的变化，且都贴合抓取部位。其中，抓取手势变化最为明显的地方是灵巧手的张开程度，这反应了抓取部位对网络预测结果的影响。可以得出结论：在不同物体的抓取部位、相同抓取位姿的情况下，网络预测的抓取手势与被抓取部位息息相关，验证了网络结构中图像输入的合理性。

(2) 第二组仿真实验

选择圆锥体的某一抓取，固定灵巧手的抓取位置，旋转灵巧手得到不同的灵巧手姿态。由于灵巧手的位置是固定的，因此物体被抓取部位的图片一致，如图 4.10 所示。图左边是物体的整体深度图、抓取区域深度图和灵巧手位姿，图右侧是不同位姿下预测的抓取手势。图右侧从左往右灵巧手绕竖直轴旋转，从上往下灵巧手绕水平轴旋转。

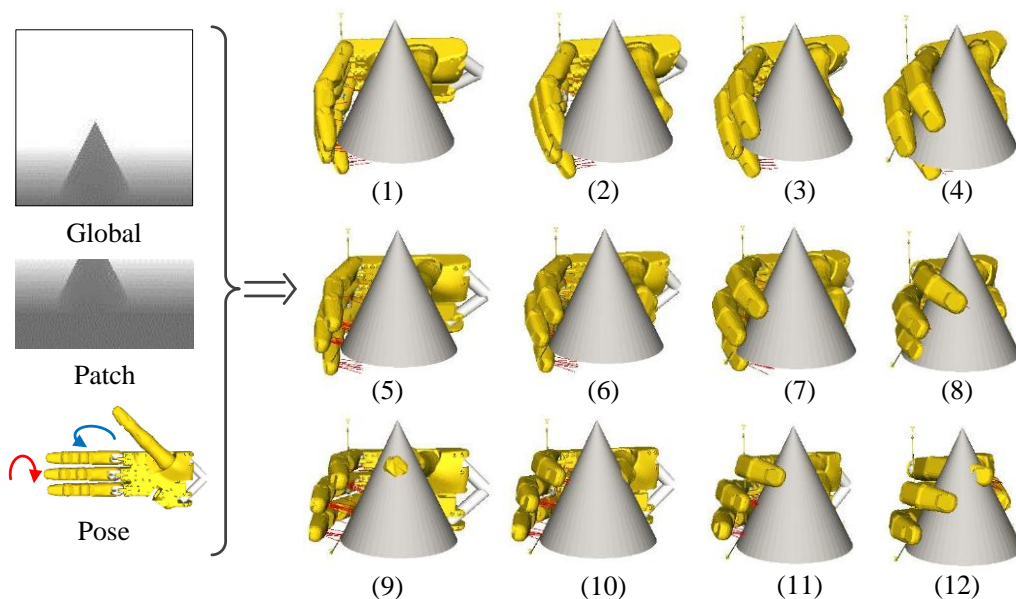


图 4.10 第二组仿真实验结果图

从实验结果对比图 4.10 中可以看出，只有 (9) 和 (12) 号的抓取手势较差，其余抓取手势都根据位姿进行了相应的调节且都贴合物体。因此可以验证在相同抓取部位、不同抓取姿态的情况下，抓取手势预测网络能够适应不同的灵巧手姿态，预测合适的抓取手势。验证了网络结构中灵巧手位姿输入的合理性。

通过上述的两组仿真实验，验证了改进型抓取手势预测网络结构的合理性，并且证明了改进型抓取手势预测网络的有效性。

4.6.2 仿真对比实验

在仿真环境 GraspIt! 中，进行本章所提抓取规划方法与其他三种方法的抓取对比实验，对比实验的流程图如图 4.11 所示。第一个对比是与 GraspIt! 自带的抓取规划方法对比。首先记录实验最开始阶段在 GraspIt! 中对每个物体生成的 10 次抓取，并保存它们的抓取质量数据；接着在 Gazebo 中采集测试物体的深度图，并根据 GraspIt! 生成的抓取数据得到物体的整体深度图和被抓部位的深度图；之后将图片数据和位姿数据导入改进型抓取手势预测网络模型中，得到抓取手势；最后，将抓取手势导入 GraspIt! 中进行完整的抓取过程，记录最终的抓取质量。

除了 GraspIt! 自带的抓取规划方法，第二种抓取规划方法是确定灵巧手手掌的位姿，最后将灵巧手最大程度地张开再闭合直到接触物体，本文称这种方法为直接抓取，本次对比实验使用的灵巧手手掌位姿就是实验中 GraspIt! 生成的。

第三种抓取规划方法是利用卷积神经网络在物体图像中预测灵巧手手掌点和指尖点的位置，再通过点云数据得到它们的三维位置，最后通过运动学反解 (Inverse Kinematics) 得到灵巧手的关节值，实现未知物体抓取。本文称这种方法为预测接触点抓取，同样将该方法导入 GraspIt! 中计算抓取质量。

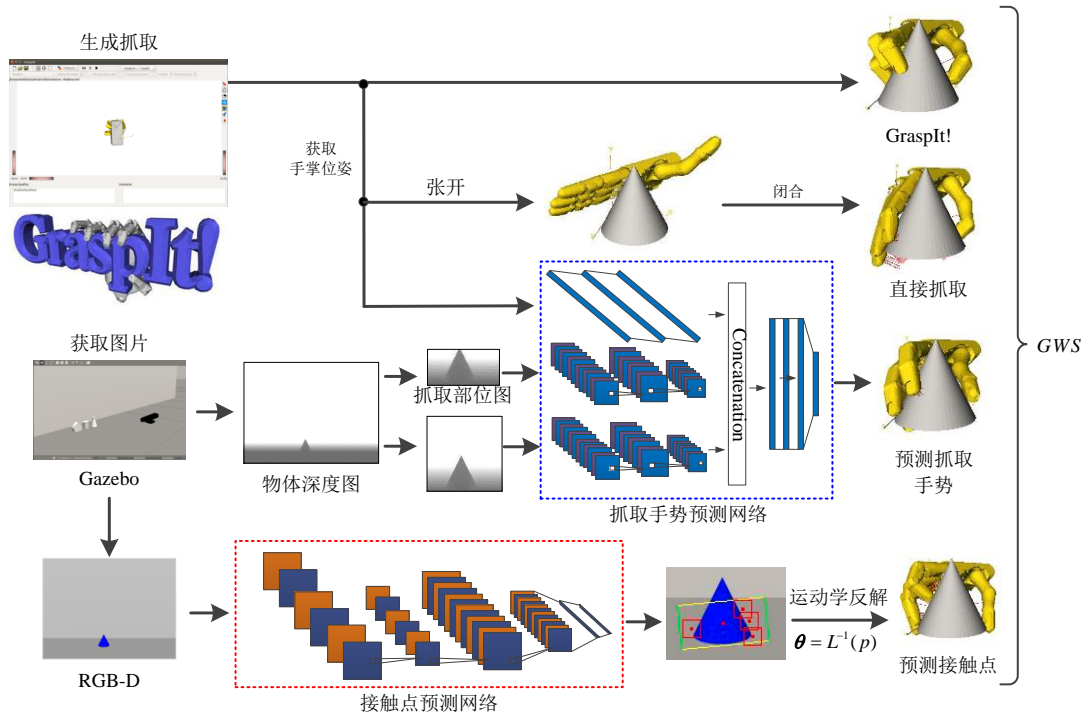


图 4.11 对比实验流程图

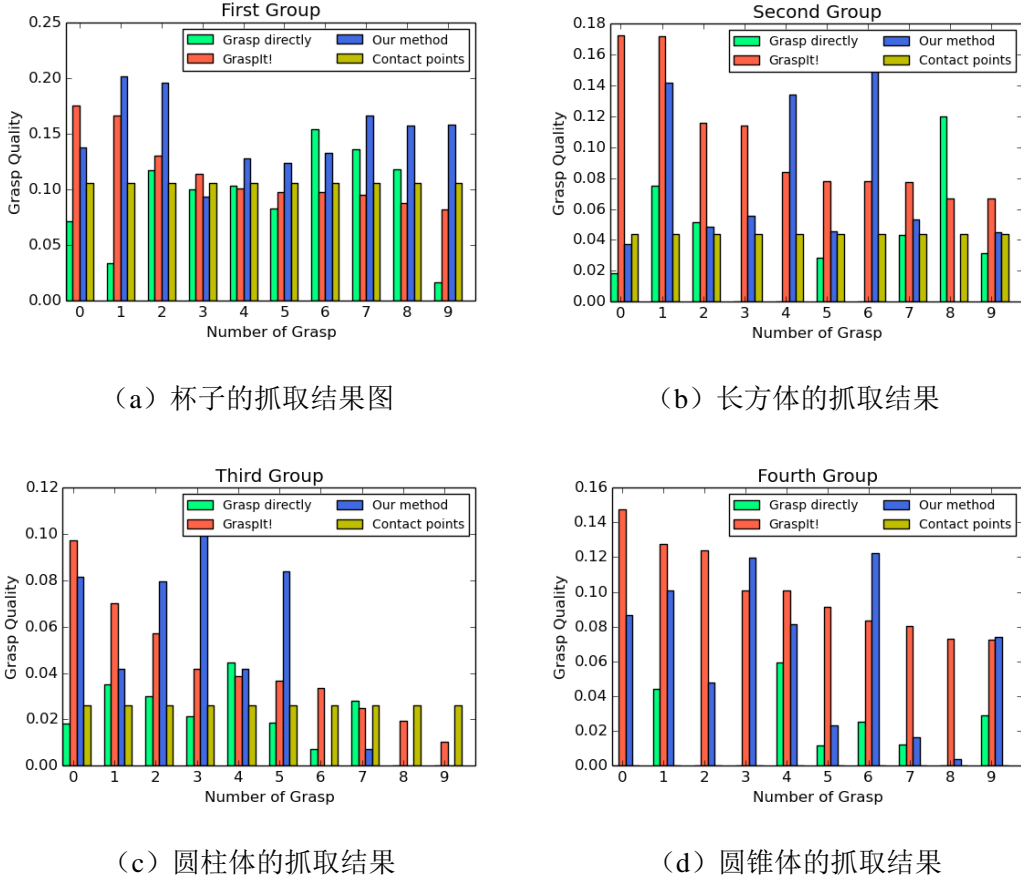


图 4.12 仿真对比实验结果图

实验结果如图 4.12 所示，图 4.12 中 (a)、(b)、(c) 和 (d) 分别是杯子、长方体、圆柱体和圆锥体的抓取对比结果。相对于 GraspIt! 自带方法和本文所提的直接抓取方法，预测接触点抓取方法对一个物体只预测一组最优接触点。因此这种方法对于每个物体只有一次抓取，所以在实验结果图中预测接触点抓取方法只有一种结果。由于预测接触点抓取方法只是提供了抓取接触点并未考虑灵巧手的运动学模型，因此存在某些接触点灵巧手无法到达的情况，从而导致灵巧手抓取失败。实验中圆锥体的抓取正是出现了这种情况，所以图 4.12 (d) 中没有预测接触点抓取的结果。比较其余物体的抓取结果，黄色矩形图基本处在中下部位，说明预测接触点抓取在其余物体上也没有得到高质量的抓取。可能的原因是即使接触点可以到达，也很难将手指精确地定位在接触点上，因为定位末端执行器总是存在不可避免的误差。从未知物体抓取的对比实验结果图可以看出，红色矩形图和蓝色矩形图不仅在抓取成功次数上接近而且它们的抓取质量也不相上下，说明本文方法足以与 GraspIt! 媲美，实现了在实际操作中便捷地得到高质量的灵巧手抓取位形的目标。从图 4.12 (a) 可以看出，GraspIt! 和本文的方法并没有优于直接闭合的方法，主要原因是杯子的尺寸十分便于灵巧手抓取。但是对于圆锥体，直接

闭合方法抓取成功率以及抓取的质量就十分低下。综上所述，本文的方法普遍优于其他方法，证明了本文方法的有效性。

4.7 实际实验

本节将通过实际实验验证多级抓取网络的实用性。本节用于抓取实验的机器人系统是由 Shadow Hand Lite 灵巧手和 UR5 机械臂组成的拟人手臂系统。灵巧手具有 16 个关节，UR5 具有 6 个关节。灵巧手型号为 G1M4R，指尖有压力传感器。对于物体图像的采集，本节使用微软公司的 Kinect v2 相机，Kinect2.0 具有彩色摄像头和深度摄像头，能够提供物体的 RGB 图像和点云数据。整个系统通过机器人操作系统(ROS)进行通信，完整的实验平台如图 3.6 所示。

抓取框检测网络用来检测物体上的最佳抓取部位，确定灵巧手相对于物体的位姿。并在深度图上将抓取框区域的图像裁剪下来，将位姿数据和图像数据作为抓取手势预测网络的输入。紧接着，抓取手势预测网络实现从物体最佳抓取部位图像和抓取位姿到抓取手势的映射。将两者结合在一起，实现拟人手臂系统的自主抓取。

实验过程分为四个阶段：1)、Kinect v2 相机获取物体 RGB-D 图像信息，将图像信息输入到网络中，得到物体上的抓取框。2)、根据抓取框，计算灵巧手手掌相对于物体的位姿。将抓取框区域的深度图和灵巧手手掌的位姿信息输入到网络中，预测抓取手势。同时规划机械臂接近物体，达到灵巧手接近物体的目的。3)、当灵巧手接近物体时，根据网络输出得到的抓取手势，使灵巧手达到指定手势。4)、最后闭合灵巧手，通过指尖的压力传感器判断手指是否与物体接触，接着举起物体并维持 5 秒钟以检测抓取是否成功。



图 4.13 六个物体的部分抓取结果

实际抓取实验一共选择了6个未知物体对多级网络进行测试,对每个物体进行10次抓取实验且每次抓取实验中物体的位姿都不相同,抓取成功率如表4.1所示,部分抓取结果如图4.13所示。图4.13给出了对应物体的抓取手势以及物体的最终抓取状态。

从表4.1可以看出,通过多级网络,灵巧手对测试物体的抓取成功次数都达到了8/10以上,其中更有3个物体的抓取成功率达到了10/10,抓取成功率很高。对于最难抓取的漏斗,抓取成功率都达到了8/10。与上一章的实际实验结果对比,本章提高了未知物体的抓取成功率,说明本章所设计的网络结构能够成功地与多指灵巧手结合完成物体抓取。实际抓取实验结果验证了改进型抓取手势预测卷积神经网络的泛化能力,能够预测未知物体的抓取手势,从而实现对未知物体进行精细抓取。

表 4.1 实际抓取实验的抓取成功率

物体	成功率	物体	成功率
漏斗	8/10	长方体盒子	10/10
易拉罐	10/10	茶叶盒	9/10
墨粉盒	10/10	工具盒	8/10

4.8 本章小结

本章分析了第三章中抓取手势预测网络存在的问题,对网络结构进行了调整,在网络输入中额外添加了物体的整体深度图和灵巧手手掌位姿,并且在GraspIt!中采集训练数据,弥补了原先网络的不足之处。从仿真实验结果可以看出,抓取手势预测网络生成了高质量的抓取,验证了网络的有效性以及网络的泛化能力。在实际实验中,提升了对未知物体的抓取成功率,进一步表明了抓取手势预测网络的有效性。

第5章 基于手势优化的灵巧手抓取规划

改进型的灵巧手抓取手势预测网络提供了稳定的抓取手势,提高了未知物体的抓取成功率。但是网络学习到的是灵巧手抓取数据集中的平均抓取手势,导致网络生成抓取质量(GWS)相对较低的手势。为了提高灵巧手抓取手势的质量,本章训练一个预测灵巧手抓取质量的卷积神经网络。它可以被视为物体图像信息和灵巧手抓取位形的函数,依靠卷积神经网络的反向传播算法计算梯度,利用梯度上升算法优化灵巧手的抓取手势。

5.1 问题分析

第四章所提出的灵巧手抓取手势预测网络能够提供稳定的抓取手势,未知物体的抓取成功率也很高。但从第四章仿真对比实验结果图 4.12 可以看出,抓取手势预测网络并非每次都生成高质量的抓取手势,甚至其中还有几次失败的抓取,如长方体的第8次抓取、圆柱体的第6、8和9次抓取。与 GraspIt!生成的抓取进行对比,可以发现抓取手势预测网络所生成的抓取手势还有提升的空间。原因之一是原有的抓取数据集中存在着相似的抓取位姿,但抓取质量不同的抓取手势,导致网络学到了它们的平均抓取手势;另一原因是 GraspIt!是通过搜索生成抓取手势的,因此可能导致抓取数据集中的抓取手势并不都是最优的抓取手势。由于抓取手势预测网络直接输出抓取手势,不存在反馈调节,所以无法对失败的抓取进行重新规划。因此我们希望能够对抓取手势进行优化,重新规划失败的抓取。对于优化问题,一般都需要选择一个优化指标。显然,这里选择抓取质量力封闭指标作为抓取手势优化问题的优化指标,因此需要计算灵巧手抓取的力封闭指标。但是在实际场景中计算抓取力封闭指标需要精确的物体三维模型和灵巧手与物体的接触信息,而在现实环境中通常难以获取这些信息。并且本文中抓取的对象是未知物体,只有单一方向上的物体图像信息。

为了解决上述问题,便捷地计算灵巧手抓取的力封闭指标,本章设计了一种预测灵巧手抓取质量的卷积神经网络。通过输入物体图像信息和灵巧手抓取位形,预测在此抓取位形下的抓取质量。这个卷积神经网络能够在没有任何接触信息,并且物体视图是单一方向的情况下计算抓取质量,非常便利。之后,将抓取质量预测网络视为抓取质量关于抓取位形和物体图像的函数,通过卷积神经网络的反向传播算法,计算灵巧手抓取手势的梯度。利用梯度上升算法优化灵巧手的抓取手势,从而提高灵巧手抓取物体时的抓取质量。通过对抓取失败的手势进行优化,重新生成抓取手势,从而减少抓取失败的次数。

5.2 网络结构设计

考虑到抓取未知物体时，只有相关的传感器数据，如物体单一方向上的图像信息、灵巧手的关节数据和位姿数据等，除此之外没有任何物体的详细信息，如物体精确的三维数据。在给定相关传感器数据的情况下，我们需要解决的问题是计算当前抓取状态下的抓取质量。为了解决这个问题，本章设计了一个卷积神经网络用来预测灵巧手的抓取质量。网络的输入只有给定的传感器数据，包括物体的深度图、灵巧手手掌的位姿以及灵巧手的抓取手势，网络的输出是当前抓取位形下灵巧手的抓取质量，网络结构图如图 5.1 所示。网络的图像输入与改进型抓取手势预测网络一样，包括物体的整体深度图 128×128 和物体被抓取部位的深度图 64×128 。物体的整体深度通过两层卷积层以及一层最大池化层，两层卷积层的核大小分别为 12×12 和 6×6 ，步进大小为 2×2 ，卷积核的数目分别为 32 和 8。最大池化层的核大小和步进大小均为 2×2 。抓取区域的深度图也通过一样结构的网络层，只不过卷积层的核大小分别为 6×6 和 3×3 。由于位姿数据的量纲与抓取手势的量纲是不同的，所以它们要通过不同的全连接层，再并列在一起。其中，网络输入的位姿数据也与改进型抓取手势预测网络一致，抓取位姿则通过两层全连接层，每层均有 32 个神经元，神经元的激活函数是 ReLU。抓取手势数据也通过两层，但每层神经元个数为 64。最后，将四者的输出连接在一起通过四层全连接层，神经元个数分别为 1000、100、64 和 32。最后一层为整个网络的输出层，共有 1 个神经元，输出抓取质量。

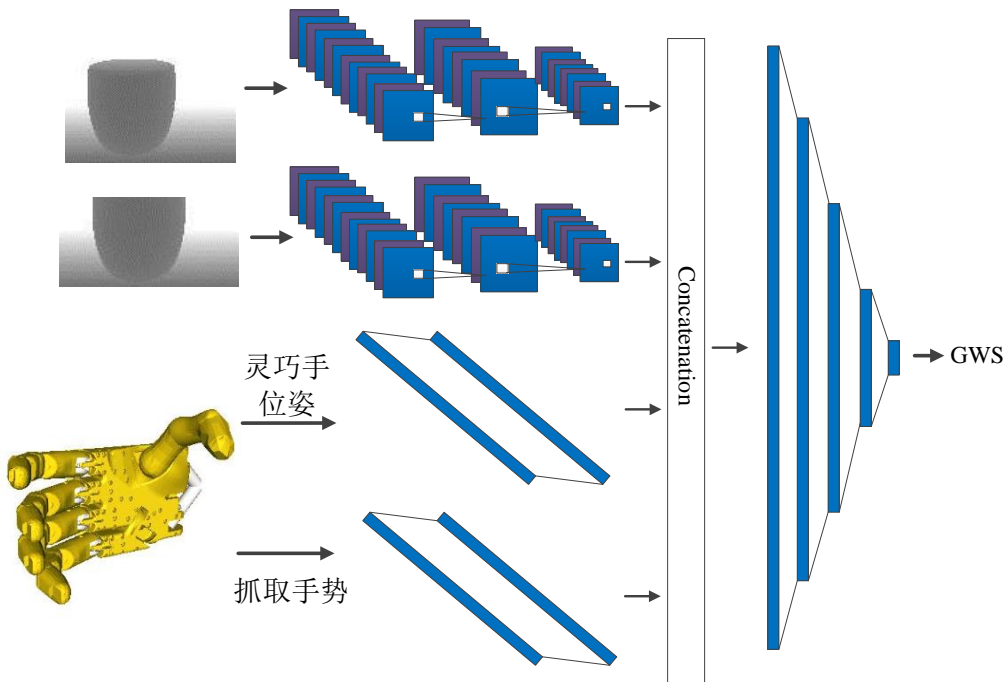


图 5.1 抓取质量预测网络结构图

5.3 数据集的生成和网络的训练

数据集的生成过程与第四章中的数据集生成过程一致，也是在 GraspIt! 中生成灵巧手的抓取位形，只不过额外保存了抓取质量。同样的，在 Gazebo 中采集物体的深度图，再根据灵巧手手掌的位姿裁剪出物体的整体深度图和物体被抓取部位的深度图。

将式 (3.5) 定义的 MSE 损失函数作为网络的损失函数，通过批量梯度下降法进行优化训练，采用 Adam 优化器，批量大小为 20，迭代次数为 5000 次。在网络训练之前，将深度图和抓取质量进行归一化，使得它们的值均在 0-1 之间。将采集得到的数据集随机分为两部分，其中 80% 的数据作为训练数据，另外的 20% 数据作为验证集数据。在网络训练过程中，设置学习速率为 0.0003，并且保证每次迭代训练完成后训练数据集的顺序被打乱。为了防止网络过拟合，本章采用早停技术，当网络的验证集误差不再下降时保存网络的参数。

5.4 优化抓取手势

通过上节的训练过程得到一个抓取质量预测网络，给定物体图片和灵巧手抓取位形，计算当前的灵巧手抓取质量，通过最大化抓取质量，优化在当前抓取位姿下的抓取手势。将抓取质量预测网络视为抓取质量关于物体图像 d 、灵巧手抓取位姿 x 和灵巧手抓取手势 θ 的函数，优化抓取手势：

$$\begin{aligned} & \arg \max_{\theta} f(d, x, \theta, w) \\ & \text{subject to } \theta_{\min} \leq \theta \leq \theta_{\max} \end{aligned} \quad (5.1)$$

其中， $f(d, x, \theta, w)$ 表示灵巧手抓取的抓取质量， w 代表网络的参数，将灵巧手的关节限制设为约束条件，直接优化抓取手势 θ 以最大化抓取质量。

为了有效求解这个优化问题，本章利用网络的结构有效地计算梯度，再使用梯度上升的方法进行求解。利用网络训练过程中的反向传播算法计算当前状态下抓取手势的梯度 $\partial f / \partial \theta$ 。

完整的抓取手势优化过程如图 5.2 所示，将当前的物体图片 d 、灵巧手抓取位姿 x 以及初始灵巧手抓取手势 θ^0 作为网络输入，通过网络的前向传播计算此时的抓取质量。接着，利用反向传播算法计算梯度，使用梯度上升算法更新抓取手势 θ 。最后，不断迭代前向和反向传播直到收敛。本章使用梯度投影处理优化中的线性约束，并应用回溯线搜索来确定每次迭代时的步长。本章中使用的初始化手势是上一章改进型抓取手势预测网络生成的抓取手势。

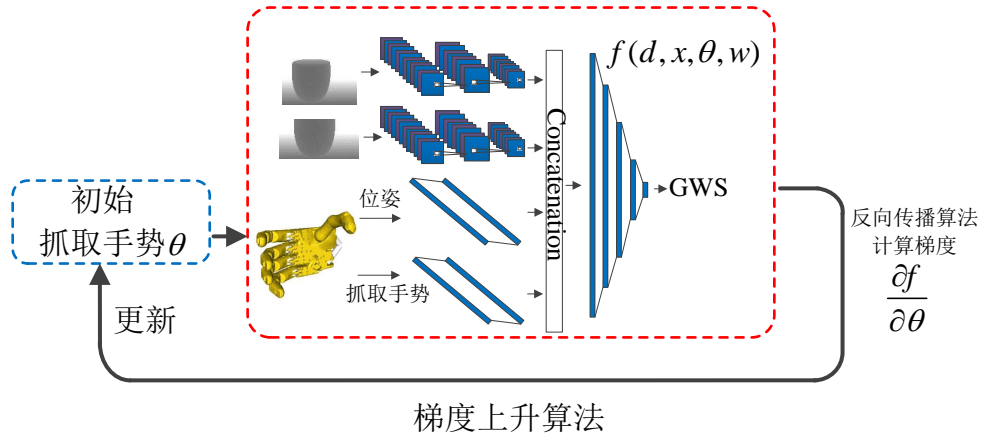


图 5.2 抓取手势优化过程

5.5 实验结果

本节在 GraspIt! 仿真软件中评估所设计的抓取手势优化过程。优化的抓取对象是第四章仿真对比实验中抓取网络所生成的抓取，提高抓取网络所生成的抓取手势的抓取质量，甚至将抓取失败的手势优化为成功的抓取手势。首先，将第四章仿真对比实验中的物体深度图、抓取位姿以及网络预测的抓取手势输入抓取质量预测网络，其中抓取手势预测网络输出的灵巧手手势作为优化过程的初始手势。接着，采用上一节所设计的优化过程更新抓取手势。最后，使用优化后的抓取手势进行抓取。优化过程中，限制灵巧手的关节角度，每次抓取优化的迭代次数是 100。设置回溯线搜索的初始步长为 1，每次梯度上升步的最大迭代次数为 10，回溯线搜索的控制参数设为 0.8。

在第四章仿真对比实验中，改进型抓取手势预测网络完成了多次抓取操作，但是其中有些抓取的抓取质量并不是很高，甚至还有几次抓取失败了。如图 4.12 所示，图 4.12(b) 长方体抓取结果中第 8 次抓取失败，图 4.12(c) 圆柱体抓取结果中第 6、8 和 9 次均抓取失败。将抓取失败的手势进行优化，重新进行抓取，得到的结果如表 5.2 所示。

表 5.2 抓取手势优化结果表

	优化前	优化后
长方体第 8 次抓取	-1	0.01056
圆柱体第 6 次抓取	-1	0.00348
圆柱体第 8 次抓取	-1	0.01023
圆柱体第 9 次抓取	-1	-1

四次抓取结果如图 5.3 所示，图中从左往右依次是长方体第 8 次抓取、圆柱体第 6 次抓取、圆柱体第 8 次抓取以及圆柱体第 9 次抓取。其中，圆柱体第 9

次抓取失败的根本原因是抓取位姿有问题,在这种位姿下难以找到合适的抓取手势,因此优化前后的抓取都是失败的。从优化结果中可以看出,本章所提出的抓取手势优化过程能够优化失败的抓取手势,提高抓取成功率,验证了抓取手势优化算法的性能。




图 5.3 抓取手势优化结果图

除了优化失败的抓取手势外,本章还对第四章仿真对比实验中的低抓取质量的抓取手势进行了优化。选择仿真实验中 15 次低抓取质量的抓取,对这 15 次抓取的抓取手势进行优化,优化前后的抓取质量如表 5.3 所示。由于优化指标是网络预测的抓取质量并非实际的抓取质量,因此实验结果中存在优化后实际抓取质量降低甚至抓取失败的情况。但是对这 15 次低抓取质量的抓取进行优化,其中 60%的抓取手势经过优化后,其抓取质量得到了提高,实验结果验证了本章抓取手势优化算法的可行性。

表 5.3 抓取手势优化结果表

	优化前抓取质量	优化后抓取质量
1	0.0371	0.1952
2	0.0557	-1.0
3	0.0455	0.0542
4	0.0488	0.0509
5	-1.0	0.0152
6	0.0452	0.0533
7	-1.0	-1.0
8	-1.0	0.0035
9	0.0070	-1.0
10	-1.0	0.0102
11	0.0165	-1.0
12	0.0038	-1.0
13	0.0477	0.0239
14	0.0229	0.0342
15	0.0868	0.1536

5.6 本章小结

本章针对改进型抓取手势预测网络生成的抓取手势还有提升空间的问题,设计了一种抓取手势优化方法。首先,训练了一个抓取质量预测网络,能够在只有物体图像信息和灵巧手抓取位形信息的情况下,预测当前抓取质量。接着,根据卷积神经网络的反向传播算法计算梯度,通过梯度上升算法优化抓取手势。在仿真环境 **GraspIt!** 中,将失败的抓取手势优化为成功的抓取手势,验证了抓取手势优化算法的有效性。

第6章 总结与展望

6.1 总结

本文围绕多指灵巧手抓取规划问题,总共设计了三种不同结构和功能的卷积神经网络,实现了多指灵巧手抓取未知物体。

1) 针对分析法无法应用于实际场景的问题,本文提出了一种实用的抓取规划算法,实现了多指灵巧手抓取未知物体。本文参考人类抓取过程,并考虑物体抓取框和物体局部图像,设计了一种新颖的四级卷积神经网络,每级网络具有不同功能,可以有效模拟人类抓取过程:判断物体位置、选择抓取部位以及确定最优抓取手势,实现从未知物体 RGB-D 信息到多指灵巧手位姿与手势的映射。第一级网络定位物体的大致位置,确定抓取框的搜索范围。第二级网络在第一级网络的基础上,搜索得到可用的预选抓取框。第三级网络准确评估所得到的预选抓取框,获得最佳抓取框,确定多指灵巧手手掌相对于物体的位姿。第四级网络通过最佳抓取框区域的深度图,预测多指灵巧手的抓取手势。将前三级网络称为抓取框检测网络,最后一级网络命名为抓取手势预测网络。基于力封闭指标,设计了多指灵巧手的抓取品质定量评估方法,并在仿真环境 GraspIt!中进行测试。在实际的多指灵巧手 Shadow Hand Lite 上进行了抓取实验,结果表明所提出的多级卷积神经网络方法可以有效完成大量未知物体的精细抓取,并应用所设计的抓取品质定量评估方法,进一步验证所提出的多级卷积神经网络具有较好的抓取品质。

2) 通过分析抓取手势预测网络的不足之处,改进了抓取手势预测网络的结构,进一步提升了网络的性能和实用性,从而完善多指灵巧手抓取未知物体的过程。由于灵巧手的抓取手势不仅与目标物体的被抓取部位有关,还与灵巧手的抓取位姿相关,同时考虑到物体被抓取部位没有物体的厚度信息。因此,本文设计了一个多输入的抓取手势预测网络,将物体的整体深度图、抓取框区域的深度图以及灵巧手手掌的抓取位姿作为输入,改进后的抓取手势预测网络弥补了原有网络的不足之处,提升了灵巧手的抓取能力。从仿真实验结果可以看出,改进型抓取手势预测网络生成了高质量的抓取,证明了网络的有效性以及网络的泛化能力。在实际实验中,提升了对未知物体的抓取成功率,说明了改进型抓取手势预测网络的实用性。

3) 针对抓取手势预测网络得到的抓取手势还有提升空间的问题,设计了一种抓取手势优化算法。本文训练了一个预测灵巧手抓取质量的卷积神经网络,网络的输入是物体图像和灵巧手抓取位形。网络可以被视为物体图像信息和灵巧手

抓取位形的函数，依靠卷积神经网络的反向传播算法，计算抓取手势相对于抓取质量的梯度，最后利用梯度上升算法优化灵巧手的抓取手势。仿真实验结果证明本文所提出的优化算法能有效地对抓取手势进行优化，证明了算法的有效性。

6.2 展望

虽然本文在多指灵巧手抓取规划方面做了一些研究，但由于时间和本人能力有限，还存在一些问题需要进一步分析和研究。

本文所设计的多级灵巧手抓取网络虽然经过改进，能够生成高质量的抓取手势，但是还是存在一些问题。在实际实验中，灵巧手手掌的位姿是根据抓取框的位姿以及物体的倾斜表面确定的，对于表面平滑的物体，这种方法是没有任何问题的，但是一旦物体表面凹凸不平，可能会得到奇异的灵巧手姿态，导致抓取失败。因此，需要进一步改进灵巧手位姿生成算法，如改进抓取框检测网络，将物体点云数据作为网络输入，将网络中的二维卷积改为三维卷积，直接使抓取框检测网络生成三维空间下的抓取框，从而得到更好的灵巧手手掌位姿。

本文对多指灵巧手抓取规划研究只考虑了物体的形状，而在实际抓取中，物体的质量以及质量分布对抓取也是有影响的。在实际实验中，灵巧手的抓取力是固定的，如果物体质量过大，在抓取过程中物体可能会滑落。因此需要对抓取过程进行实时调节，如果采用循环神经网络根据当前抓取的状况输出下一时刻的抓取力，不断调节灵巧手的抓取状态，则能实现更稳定的灵巧手抓取。

除了物体的质量会影响灵巧手抓取外，物体表面的粗糙程度同样会影响抓取的质量。如果在灵巧手上安装灵敏的触觉传感器，将视觉和触觉相结合用于灵巧手重复抓取，调整抓取阶段的灵巧手手势和抓取力。从而解决灵巧手抓取过程中抓握物体不稳定的问题，进一步提高灵巧手抓取性能，提升机器人与环境的交互能力，在未来的人机交互中有着重要的应用前景。

参考文献

- [1] 刘宏, 姜力. 仿人多指灵巧手及其操作控制[M]. 北京: 科学出版社, 2010.
- [2] Tomovic R, Boni G. An adaptive artificial hand[J]. IRE Transactions on Automatic Control, 1962, 7(3): 3-10.
- [3] Okada T. An artificial finger equipped with adaptability to an object[J]. Bull. electrotech. lab, 1974, 37(2): 1078-1090.
- [4] Jacobsen S, Iversen E, Knutti D, et al. Design of the Utah/MIT dextrous hand[C]//Proceedings. 1986 IEEE International Conference on Robotics and Automation. San Francisco, USA : IEEE, 1986, 3: 1520-1532.
- [5] Salisbury J K, Roth B. Kinematic and force analysis of articulated mechanical hands[J]. Journal of Mechanisms, Transmissions, and Automation in Design, 1983, 105(1): 35-41.
- [6] Caffaz A, Cannata G. The design and development of the DIST-Hand dextrous gripper[C]//Proceedings. 1998 IEEE International Conference on Robotics and Automation (Cat. No. 98CH36146). Leuven, Belgium: IEEE, 1998, 3: 2075-2080.
- [7] Melchiorri C, Vassura G. Implementation of whole-hand manipulation capability in the UB hand system design[J]. Advanced robotics, 1994, 9(5): 547-560.
- [8] Hirzinger G, Fischer M, Brunner B, et al. Advances in robotics: the DLR experience[J]. The International Journal of Robotics Research, 1999, 18(11): 1064-1087.
- [9] Butterfass J, Hirzinger G, Knoch S, et al. DLR's multisensory articulated hand. I. Hard-and software architecture[C]//Proceedings. 1998 IEEE International Conference on Robotics and Automation (Cat. No. 98CH36146). Leuven, Belgium: IEEE, 1998, 3: 2081-2086.
- [10] Lovchik C S, MDifler M A. The Robonaut Hand: A Dextrous Robotic Hand for Space [J][C]//Proceedings for the IEEE International Conference on Robotics and Automation. Detroit, Michigan, 1999. 907-912.
- [11] Butterfaß J, Grebenstein M, Liu H, et al. DLR-Hand II: Next generation of a dextrous robot hand[C]//IEEE International Conference on Robotics and Automation. Piscataway, USA: IEEE, 2001: 109-114.
- [12] Mouri T, Kawasaki H, Yoshikawa K, et al. Anthropomorphic robot hand: Gifu hand III[C]//Proc. Int. Conf. ICCAS. Muju Resort, Korea. 2002: 1288-1293.
- [13] Kochan A. Shadow delivers first hand[J]. Industrial robot: an international journal, 2005, 32(1): 15-16.
- [14] 王国庆, 李大寨, 钱锡康, et al. 新型三指灵巧机械手的研究[J]. 机械工程学报, 1997, 33(3):71-75.

- [15] Zhang Y, Han Z, Zhang H, et al. Design and control of the BUAA four-fingered hand[C]//Proceedings 2001 ICRA. IEEE International Conference on Robotics and Automation (Cat. No. 01CH37164). Seoul, Korea: IEEE, 2001, 3: 2517-2522.
- [16] Gao X H, Jin M H, Jiang L, et al. The HIT/DLR dexterous hand: Work in progress[C]//2003 IEEE International Conference on Robotics and Automation (Cat. No. 03CH37422). Taipei, Taiwan: IEEE, 2003, 3: 3164-3168.
- [17] Liu H, Wu K, Meusel P, et al. Multisensory five-finger dexterous hand: The DLR/HIT Hand II[C]//2008 IEEE/RSJ international conference on intelligent robots and systems. Nice, France: IEEE, 2008: 3692-3697.
- [18] Sahbani A, El-Khoury S, Bidaud P. An overview of 3D object grasp synthesis algorithms[J]. Robotics and Autonomous Systems, 2012, 60(3): 326-336.
- [19] Bohg J, Morales A, Asfour T, et al. Data-driven grasp synthesis—a survey[J]. IEEE Transactions on Robotics, 2014, 30(2): 289-309.
- [20] Kirkpatrick D, Mishra B, Yap C K. Quantitative steinitz's theorems with applications to multifingered grasping[J]. Discrete & Computational Geometry, 1992, 7(3): 295-318.
- [21] Ferrari C, Canny J F. Planning optimal grasps[C]//IEEE International Conference on Robotics and Automation. Atlanta, USA: IEEE. 1992, 3: 2290-2295.
- [22] Ciocarlie M T, Allen P K. Hand posture subspaces for dexterous robotic grasping[J]. The International Journal of Robotics Research, 2009, 28(7): 851-867.
- [23] Nguyen V D. Constructing force-closure grasps[J]. The International Journal of Robotics Research, 1988, 7(3): 3-16.
- [24] Roa M A, Suárez R. Computation of independent contact regions for grasping 3-d objects[J]. IEEE Transactions on Robotics, 2009, 25(4): 839-850.
- [25] Dragiev S, Toussaint M, Gienger M. Gaussian process implicit surfaces for shape estimation and grasping[C]//2011 IEEE International Conference on Robotics and Automation. Shanghai, China: IEEE, 2011: 2845-2850.
- [26] Hang K, Stork J A, Kragic D. Hierarchical fingertip space for multi-fingered precision grasping[C]//IEEE/RSJ International Conference on Intelligent Robots and Systems. Piscataway, USA: IEEE, 2014: 1641-1648.
- [27] Miller A T, Allen P K. Graspit! a versatile simulator for robotic grasping[J]. IEEE Robotics & Automation Magazine, 2004, 11(4): 110-122.
- [28] León B, Ulbrich S, Diankov R, et al. OpenGRASP: A toolkit for robot grasping simulation[C]//2nd International Conference on Simulation, Modeling, and Programming for Autonomous Robots. Berlin, Germany: Springer, 2010: 109-120.

- [29] Zaidi L, Corrales J A, Bouzgarrou B C, et al. Model-based strategy for grasping 3D deformable objects using a multi-fingered robotic hand[J]. *Robotics and Autonomous Systems*, 2017, 95(C): 196-206.
- [30] Levine S, Pastor P, Krizhevsky A, et al. Learning hand-eye coordination for robotic grasping with large-scale data collection[C]//*International Symposium on Experimental Robotics*. Cham, Germany: Springer, 2016: 173-184.
- [31] Johns E, Leutenegger S, Davison A J. Deep learning a grasp function for grasping under gripper pose uncertainty[C]//*IEEE/RSJ International Conference on Intelligent Robots and Systems*. Piscataway, USA: IEEE, 2016: 4461-4468.
- [32] Saxena A, Driemeyer J, Ng A Y. Robotic grasping of novel objects using vision[J]. *The International Journal of Robotics Research*, 2008, 27(2): 157-173.
- [33] Le Q V, Kamm D, Kara A F, et al. Learning to grasp objects with multiple contact points[C]//*2010 IEEE International Conference on Robotics and Automation*. Anchorage, USA: IEEE, 2010: 5062-5069.
- [34] Jiang Y, Moseson S, Saxena A. Efficient grasping from rgb-d images: Learning using a new rectangle representation[C]//*2011 IEEE International Conference on Robotics and Automation*. Shanghai, China: IEEE, 2011: 3304-3311.
- [35] Lenz I, Lee H, Saxena A. Deep learning for detecting robotic grasps[J]. *The International Journal of Robotics Research*, 2015, 34(4-5): 705-724.
- [36] Redmon J, Angelova A. Real-time grasp detection using convolutional neural networks[C]//*2015 IEEE International Conference on Robotics and Automation (ICRA)*. Seattle, USA: IEEE, 2015: 1316-1322.
- [37] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//*Proceedings of the IEEE conference on computer vision and pattern recognition*. Las Vegas, USA: IEEE, 2016: 770-778.
- [38] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[C]//*Advances in neural information processing systems*. Montréal, Canada, 2015: 91-99.
- [39] Kumra S, Kanan C. Robotic grasp detection using deep convolutional neural networks[C]//*2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. Vancouver, Canada: IEEE, 2017: 769-776.
- [40] Guo D, Sun F, Liu H, et al. A hybrid deep architecture for robotic grasp detection[C]//*2017 IEEE International Conference on Robotics and Automation (ICRA)*. Singapore: IEEE, 2017: 1609-1614.

- [41] Chu F J, Vela P A. Deep grasp: detection and localization of grasps with deep neural networks[J]. arXiv preprint arXiv:1802.00520, 2018.
- [42] Zhou X, Lan X, Zhang H, et al. Fully convolutional grasp detection network with oriented anchor box[C]//2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Madrid, Spain: IEEE, 2018: 7223-7230.
- [43] 喻群超, 尚伟伟, 张驰. 基于三级卷积神经网络的物体抓取检测[J]. 机器人, 2018, 40(5): 762-768..
- [44] 喻群超. 基于卷积神经网络的物体抓取研究[D]. 合肥: 中国科学技术大学, 2018.
- [45] Varley J, Weisz J, Weiss J, et al. Generating multi-fingered robotic grasps via deep learning[C]//2015 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Hamburg, Germany: IEEE, 2015: 4415-4420.
- [46] Kappler D, Bohg J, Schaal S. Leveraging big data for grasp planning[C]//2015 IEEE International Conference on Robotics and Automation (ICRA). Seattle, USA: IEEE, 2015: 4304-4311.
- [47] Saxena A, Wong L L S, Ng A Y. Learning grasp strategies with partial shape information[C]//AAAI. Chicago, USA. 2008, 3(2): 1491-1494.
- [48] Zhou Y, Hauser K. 6DOF Grasp Planning by Optimizing a Deep Learning Scoring Function[C]//Robotics: Science and Systems (RSS) Workshop on Revisiting Contact-Turning a Problem into a Solution. Cambridge. 2017.
- [49] Lu Q, Chenna K, Sundaralingam B, et al. Planning multi-fingered grasps as probabilistic inference in a learned deep network[J]. arXiv preprint arXiv:1804.03289, 2018.
- [50] Ficuciello F, Zaccara D, Siciliano B. Learning grasps in a synergy-based framework[C]//International Symposium on Experimental Robotics. Springer, Cham, 2016: 125-135.
- [51] Veres M, Moussa M, Taylor G W. Modeling grasp motor imagery through deep conditional generative models[J]. IEEE Robotics and Automation Letters, 2017, 2(2): 757-764.
- [52] Zhang Y, Sohn K, Villegas R, et al. Improving object detection with deep convolutional networks via bayesian optimization and structured prediction[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Piscataway, USA: IEEE, 2015: 249-258.
- [53] Nguyen A, Kanoulas D, Caldwell D G, et al. Detecting object affordances with convolutional neural networks[C]//IEEE/RSJ International Conference on Intelligent Robots and Systems. Piscataway, USA: IEEE, 2016: 2765-2770.
- [54] Schwarz M, Schulz H, Behnke S. RGB-D object recognition and pose estimation based on

- pre-trained convolutional neural network features[C]//IEEE International Conference on Robotics and Automation. Piscataway, USA: IEEE, 2015: 1329-1335.
- [55] He K M, Zhang X Y, Ren S Q, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(9): 1904-1916.
- [56] Cornell University. Cornell grasping dataset[DB/OL]. (2015-11-31)[2016-09-01]. http://pr.cs.cornell.edu/grasping/rect_data/data.php.
- [57] Kasper A, Xue Z, Dillmann R. The KIT object models database: An object model database for object recognition, localization and manipulation in service robotics[J]. The International Journal of Robotics Research, 2012, 31(8): 927-934.

致 谢

时光飞逝，不知不觉间在中国科学技术大学已经读了三年硕士研究生，首先感谢国家和学校给予的深造机会。然后，我要感谢我的导师尚伟伟老师，他在我三年学习生涯中提供了无数的帮助，始终引导着我在科研的道路上前进，总是及时地在我误入歧途时点醒我，每次都耐心仔细地帮助我修改论文，能够成为尚老师的学生是我的荣幸，在此我真诚地感谢他的指导！我还要感谢三年来一直帮助我的实验室同学，感谢刘坤师兄、张驰师兄、喻群超师兄、张兵园师兄、葛维等同学对我的帮助，感谢他们帮我分析问题、解决问题。最后，我要感谢我的父母，感谢他们一直支持我。

此外，感谢信息科学实验中心提供的机器人和场地。

2018 年 5 月

在读期间发表的学术论文与取得的研究成果

- [1] **Fangjing Song**, Zengzhi Zhao, Wei Ge, Weiwei Shang, Shuang Cong, Learning optimal grasping posture of multi-fingered dexterous hands for unknown objects, *IEEE International Conference on Robotics and Biomimetics*, Kuala Lumpur, Malaysia, Dec. 12-15, 2018, pp. 2310-2315. 已发表.
- [2] Wei Ge, Weiwei Shang, **Fangjing Song**, Hongjian Sui, Shuang Cong, Robust and high-precision end-to-end control policy for multi-stage manipulation task with behavioral cloning, *International Conference on Cognitive Systems and Information Processing*, Beijing, Nov. 30-Dec. 01, 2018. 已发表.
- [3] 尚伟伟, 张驰, 丛爽, **宋方井**, 葛维, 一种机器人抓取飞行物体的运动规划方法及系统, 申请号: 201810608908.9, 申请日: 2018.06.13, 已公开.
- [4] 尚伟伟, 张驰, 丛爽, **宋方井**, 工业机器人平滑抓取移动物体的运动规划系统及其方法, 申请号: 201710500906.3, 申请日: 2017.06.27, 已授权.